

0123 labmeeting

윤현석

January 23, 2026

1 previous

해야 할 것.

1. simulation study 에서 multilayered LSIRM 이 더 강점을 가지는 case 를 찾아 보기
2. ordinal layer 추가 및 시뮬레이션 성능 향상(true 값을 대부분 복원하도록)
3. KSHA data 관련 염유식교수님 lab과 미팅 요청
4. real data - depression data 의 checklist, 생체 데이터를 결합하여 분석하는 사례 찾아보기

2 simulation setting

2.1 simulation 최적화

2.1.1 issue 1

ordinal layer 의 threshold가 폭발하는 문제가 있었는데요, 아래의 구조 변경이 있었습니다. ordinal item 에 대한 응답을 아래와 같이 모델링됩니다.

$$\text{logit}(P(Y_{ij} > k)) = \alpha_i - \beta_{jk} - \gamma d(z_i, z_k)$$

이 때 threshold 역할을 하는 β_{jk} 는 아래와 같은 대소관계를 가지기 때문에,

$$\beta_{i,1} < \beta_{i,2} < \dots < \beta_{i,K}$$


이를 sampling 할 때 $\delta_{j,k}$ 를 sampling 한 후 아래와 같은 변수변환을 거쳐 $\beta_{j,k-1}$ 과 $\beta_{j,k}$ 간의 차이를 아래와 같이 정의합니다.

$$\beta_{j,k-1} - \beta_{j,k} = \eta_{j,k} = \exp\{\delta_{j,k}\}$$


이 때 $\exp\{\delta_{j,k}\}$ 는 exponentially increasing 하기 때문에 threshold 값이 커질수록 추정값의 범위가 지나치게 커지고 불안정해지는 문제가 있었습니다. 따라서 변수변환 방법을 아래와 같이 바꿨습니다.

$$\beta_{j,k-1} - \beta_{j,k} = \eta_{j,k} = \log [1 + \exp\{\delta_{j,k}\}]$$


아래는 바꾼 후의 threshold 결과입니다. 추정값이 폭발하는 상황은 해결된 것으로 보입니다. 다만 모든 true 값을 복원하지는 못했으나, 대부분 값을 복원했습니다.




(a) Image 1



(b) Image 2



(c) Image 3



(d) Image 4

Figure 1: threshold MCMC sample 1-80


총 60개의 threshold 중 4개가 95% CI 안에 들어오지 못했습니다.

2.1.2 issue 2


threshold 값을 추정하는 과정에서 identifiability issue 가 발견되었습니다. 이를 해결하기 위해 모든 ordinal item 의 첫 번째 threshold 값을 0으로 고정했습니다. 따라서 ordinal item 에서 1 보다 더 큰 응답을 할 확률은 item 의 threshold 가 아니라 respondent 의 ability 와 latent variable 에 의해서 정해집니다. 또한 respondent 와 item 의 identifiability 이슈가 몇 개 발견되어 각 변수의 분산을 작게 조절했습니다. (모두 inverse gamma 를 따릅니다.)

```
1 a: a_sigma=1, b_sigma=1.5
2 b1: a_tau1=1, b_tau1=0.5
3 b2: a_tau2=1, b_tau2=0.5
4 b3: a_tau3=1, b_tau3=1
```


geometric structure 는 어느 정도 복원하는 것을 확인했는데요, true 값 복원이 되는지 확인하는 과정에서 alpha 파라미터가 beta 들에 비해서 아슬아슬하게(?) 복원이 되고 있는 상황입니다.




(a)




(b)




(c)




(d)




(e)




(f)



(g)




(h)




(i)


Figure 2: alpha - boxplot




(a) Image 1



(b) Image 2



(c) Image 3




(d) Image 4

Figure 3: threshold MCMC sample 1-80


alpha 의 경우 200개 파라미터 중 12개의 true 값을 복원하지 못했고, beta 의 경우 60개 중 3개의 true 값을 복원하지 못했습니다.

2.2 standard LSIRM 과의 비교 방법 refine

dichotomize 하는 기준을 바꿔 가면서 기존의 conditional dependency 가 어떻게 왜곡되는지를 확인할 수 있을 것 같습니다. latent position 의 군집성이 달라지는 경향성을 보여 줘야 할 것 같은데, 시뮬레이션에서는 군집성이 약화되는 모습은 보이는데, 특별히 어떤 군집이 생기고 생기지 않는지 명확하게 보이려면 세팅을 좀 다르게 줘야 할 것 같습니다. (지금까지는 군집 위치 + 분산만 설정했는데, item 과 respondent 거리 자체의 분포를 다르게 줄 수 있게끔 해야 할 듯)



(a) Image 1



(b) Image 2

Figure 4: true vs multilayer vs unilayer

3 real data analysis

MIDUS(Midlife in united states) 3rd wave data 를 사용해 볼까 합니다. 해당 데이터는 미국에서 수집된 대규모 패널 데이터로, 중년기 이후 성인의 건강·심리·사회적 요인을 장기적으로 추적하기 위해 설계되었습니다.

3 번째 wave 를 선택한 이유는 아래와 같이 해당 시기부터 survey data 에 혈액검사 결과와 같은 biomarker data 와 fmri data 를 포함하는 neuroscience data 가 포함되었기 때문입니다.

다만, 실제 fmri data 는 제공되지 않고, 자기보고 / 정신생리 / 행동 과제 성과 / 인지 기능 등 fmri data 에서부터 추출한 값들이 제공됩니다.

- 1. survey data
- 2. biomarker
- 3. neuroscience

위의 데이터를 이용하여 real data analysis 진행해 볼 생각입니다. 해당 데이터에서도 dichotomize 하여 결과 비교하는 식으로 latent position 의 왜곡 정도가 어떻게 되는지 확인할 예정입니다.

References