

May 11, 2026labmeeting

윤현석

May 11, 2026

1 [previous]

multilayered LSIRM 의 latent position clustering 을 joint 하게 수행하는 방안에 대해서 고민.

2 시도 1: item position 에 Gaussian mixture prior

2.1 모형 설정

가장 직접적인 접근은 item latent position $b_j^{(\ell)}$ 에 finite Gaussian mixture prior 를 부여하는 것이다. cluster label c_q 를 도입하여

$$z_q \mid c_q = l, \mu_l, \Sigma_l \sim N_d(\mu_l, \Sigma_l), \quad (1)$$

$$c_q \mid \rho \sim \text{Categorical}(\rho_1, \dots, \rho_{K^*}), \quad (2)$$

$$\rho \sim \text{Dirichlet}(e_0, \dots, e_0), \quad (3)$$

로 두고, mixture component 에는 conjugate Normal-Inverse-Wishart prior

$$\Sigma_l \sim \text{IW}(\nu_0, S_0), \quad \mu_l \mid \Sigma_l \sim N_d\left(m_0, \frac{1}{\kappa_0} \Sigma_l\right),$$

를 부여한다. 나머지 LSIRM parameter 의 prior 는 표준 설정 그대로 유지한다. 즉 cluster label c_q 는 *item position* *에만* 직접 영향을 주고, respondent / difficulty / nuisance parameter 에는 별도의 cluster-specific prior 를 두지 않는다.

2.2 Simulation 결과

artificial multilayered LSIRM data ($L = 4$, 충분한 cluster separation) 에서는 이 mixture prior 가 매우 잘 작동했다. cluster label 의 ARI 가 1 에 근접하고, 복원된 biplot 의 cluster 별 위치도 ground truth

와 시각적으로 거의 일치했다. posterior 의 mixing 도 안정적이고, NIW hyperprior 의 강도에 대해서도 결과가 크게 흔들리지 않았다. 즉 생성 모형의 clustering 패턴이 강할 때는 잘 working.

2.3 Real data 에서 latent geometry 가 무너지는 현상

그러나 MIDUS multilayered 자료에 동일 구조를 적용하면, partition 자체는 의미 있는 양상으로 분리되지만 (e.g. inflammation, cognition, self-report survey 그룹), *biplot* 의 *latent geometry* 가 무너지는 현상이 관찰되었다. 구체적으로는,

- posterior 의 Σ_l 이 데이터에 맞춰 매우 tight 해지면서, cluster mean μ_l 근처로 $b_j^{(\ell)}$ 들이 강하게 끌려간다.
- 그 결과 within-cluster pairwise distance 가 인공적으로 압축되고, biplot 위에서 cluster 가 *점*에 가깝게 뭉치는 형태로 collapse 한다. cluster 간 분리는 과장되고, cluster 안에서의 미세한 위계 (예: cognition 안의 처리 속도/정확도 축, inflammation 안의 acute / chronic marker 분리) 가 사라진다.

이 현상의 메커니즘은 비교적 분명하다. Σ_l 이 cluster shape 을 정의하는 parameter 인 동시에 b 의 prior precision 으로도 작동하기 때문에, posterior 가 cluster 구조를 잡아낼수록 b 가 cluster 중심으로 끌려오는 prior 압력이 강해진다. 즉 partition 정보와 geometry 정보가 같은 hyperparameter 를 통해 *얽혀* 있는 것이 원인이다. `b_prior_inflation` 과 같은 sampler-level 완화책이나, $(c_q, \rho, \mu_l, \Sigma_l)$ 을 marginalize out 한 partially collapsed Gibbs 변형 (NIW Student- t predictive 를 b -MH 의 prior 로 사용하는 방식) 도 시도해 보았으나, MIDUS 자료에서는 오히려 dominant cluster 로의 merge cascade 를 유발하거나 geometry 압축을 충분히 해소하지 못했다.

2.3.1 Simulation 결과 (figure)




Figure 1: 시도 1 (GMM prior on b) – artificial 4-layer simulation. True position 과 추정 biplot 이 거의 일치하고, co-clustering heatmap 의 block 구조가 뚜렷하다.

2.3.2 MIDUS 결과 (figure)




Figure 2: 시도 1 (GMM prior on b) – MIDUS. Partition 자체는 inflammation / cognition / self-report 그룹을 분리해 내지만, biplot 위에서 cluster 가 점에 가깝게 collapse 하여 within-cluster geometry 가 사라진다.

3 시도 2: Partition prior (EPA)

3.1 모형 설정

위 trade-off 를 해소하기 위해서는 partition 정보가 item position 의 prior 에 직접 들어가지 않도록 해야 한다. 이를 위해 mixture 의 생성 구조를 떼어 내고, item position 에는 단순한 등방성 prior 를 두는 한편 partition 에는 *Ewens–Pitman Attraction (EPA)* pairwise partition prior 를 부여한다.

먼저 item position 의 prior 는 cluster 와 무관한 isotropic Gaussian

$$b_j^{(\ell)} \sim N_d(0, \sigma_b^2 I_d), \quad \sigma_b^2 = 1,$$

로 둔다. 그 다음, item 들의 partition $\mathcal{P}$ 에 대한 prior 를 정의하기 위해 EPA pairwise similarity

$$\lambda_{qr}(z, \tau) = \exp\{-\tau \|z_q - z_r\|_2^2\}, \quad \tau \geq 0,$$

를 사용한다. item 의 Allocation permutation $\sigma \in \text{Perm}(P)$ 를 도입하면, t -번째 step 의 conditional allocation 확률은

$$\Pr(\sigma_t \in S \mid \sigma_{1:t-1}, \alpha, \delta, \tau, z) = \begin{cases} \frac{t-1-\delta q_{t-1}}{\alpha+t-1} \cdot \frac{\sum_{r \in S} \lambda_{\sigma_t r}}{\sum_{s=1}^{t-1} \lambda_{\sigma_t \sigma_s}}, & S \in \pi_{t-1}, \\ \frac{\alpha + \delta q_{t-1}}{\alpha+t-1}, & S \text{ a new subset,} \end{cases}$$

이고, 전체 EPA pmf 는 이 conditional 들의 곱으로 정의된다. mass parameter $\alpha > 0$, discount $\delta \in [0, 1)$ (구현에서는 $\delta = 0$), 그리고 temperature $\tau \geq 0$ 에는 모두 weakly informative Gamma prior 가 사용된다.

3.2 Decoupling property

EPA prior 의 핵심 장점은 *decoupling* 이다. LSIRM likelihood $p(Y \mid \Theta)$ 는 partition $\mathcal{P}$ 에 의존하지 않고, item position 의 prior 또한 $\mathcal{P}$ 에 의존하지 않는다. 결과적으로 partition 만을 바꾸는 모든 MH move (single-item Gibbs, Jain–Neal split–merge) 에서 LSIRM likelihood factor 가 acceptance ratio 에서 정확하게 cancel out 된다. partition update 의 acceptance 는 오로지 EPA pmf 와 proposal correction 의 ratio 로만 결정된다.

이 구조에서는 partition 정보가 b 의 update 에 영향을 미치지만, gaussian 과 같이 특정한 형태의 Kernel 로 영향을 미치지 않으므로, geometry 의 왜곡이 상대적으로 덜 할 것이라고 예상.

3.3 Real data 에서 clustering pattern 을 못 잡는 현상

기대대로 latent geometry 는 잘 유지되었고, hierarchical clustering 으로 $\hat{z}$ 에 대해 그은 컷도 의미 있는 grouping 을 제공함.

그러나 partition posterior 의 posterior similarity matrix (PSM) 가 지나치게 모호한 문제가 있었음.

- PSM 의 within-true-cluster 평균과 between-true-cluster 평균의 비가 거의 1 에 가깝다 (simulation 에서 within 0.743 vs between 0.745, ratio 1.00). 즉 partition posterior 가 거의 *uniform* 에 가깝다.
- Dahl / Binder / VI estimator 는 모두 $K = 1$ 로 collapse 한다. hierarchical clustering 으로 $\hat{z}$ 에서 직접 cut 한 경우에만 유의한 partition 이 보인다.
- 진단 결과, EPA stationary 가 사실상 $K = 1$ mode 에 머무는 시간이 매우 길고, K_+ 의 trace 평균 (e.g. 3.99) 은 큰 cluster 하나가 대부분을 차지하는 *rich-get-richer* dynamics 에 의한 평균값 이었다. mass parameter α 를 키우면 PSM contrast 는 회복되나 K_+ 가 폭발적으로 증가하고, 줄이면 곧바로 $K = 1$ 로 collapse 한다.

즉 EPA 는 latent geometry 와 partition 정보를 *decouple* 하는 데는 성공했지만, 그 대가로 partition 자체가 LSIRM likelihood 의 정보를 빌려올 통로 가 사라짐. EPA prior 의 sequential allocation 구조가 일단 dominant cluster 에 부여하는 prior penalty 가 너무 강해 (현 setup 에서 $K = 4$ partition 대 $K = 1$ partition 의 prior ratio 가 $\sim 1/162,000$), 데이터의 attraction 신호 가 이 prior bias 를 이기지 못한다. 결과적으로 PSM 기반의 어떤 partition estimator 도 의미 있는 분할을 회복하지 못함.

3.3.1 Simulation 결과 (figure)




Figure 3: 시도 2 (EPA partition prior) – artificial 4-layer simulation. Latent geometry 는 true 와 잘 일치하지만, co-clustering heatmap 의 block 대비가 시도 1 에 비해 약하다 (특히 가까운 cluster 쌍).

3.3.2 MIDUS 결과 (figure)




Figure 4: 시도 2 (EPA partition prior) – MIDUS. Biplot 의 latent geometry 는 잘 살아 있어 layer / domain 별 위치가 구분되지만, PSM 은 거의 균질해서 Dahl/Binder/VI 가 모두 $K = 1$ 로 collapse 한다.

3.4 현재까지의 정리

	Latent geometry	Clustering pattern
시도 1 (Gaussian mixture prior on b)	무너짐	잘 잡힘
시도 2 (EPA partition prior)	유지됨	거의 못 잡음

4 시도 3: Posterior 기반 BC coefficient + Spectral clustering

4.1 Bhattacharyya coefficient

두 확률밀도 p, q 에 대한 Bhattacharyya coefficient 는

$$BC(p, q) = \int \sqrt{p(x)q(x)} dx,$$

값은 항상 $[0, 1]$ 에 있으며, $p = q$ 일 때 1, support 가 disjoint 일 때 0 이다.

본 분석에서는 item q 의 latent position 의 marginal posterior 를 $p_q(z) = p(z_q | Y)$ 로 두고, item 쌍 (q, r) 의 similarity 를

$$BC_{qr} = \int_{\mathbb{R}^d} \sqrt{p_q(z)p_r(z)} dz$$

로 정의한다. p_q 는 posterior MCMC sample 에 kernel density estimation 을 적용해 비모수적으로 추정하
 뒤, BC_{qr} 는 numerical integration (격자 quadrature) 으로 계산한다.

이렇게 얻어진 $P \times P$ 대칭 비음 similarity matrix $B = (BC_{qr})$ 를 affinity matrix 로 하여, normalized
 Laplacian $L_{\text{sym}} = I - D^{-1/2}BD^{-1/2}$ (D 는 row-sum diagonal) 의 하위 K 개 eigenvector 를 추출하고
 row-normalization 후 k -means 로 K 개 cluster 로 분할한다 (Ng–Jordan–Weiss 2002). K 는 eigengap
 heuristic 으로 후보를 정한 뒤 $K \in \{2, 3, 4, 5\}$ 를 모두 확인하였다. (cluster 구분이 강하지 않고, elbow
 point 기준으로 하면 cluster 2 개로 결정되므로, cluster 개수를 늘려 가면서)

4.2 MIDUS 결과: $K = 2, 3, 4, 5$

다음은 MIDUS posterior 의 BC similarity 에 spectral clustering 을 적용해 얻은 결과이다. 각 K 에
 대해 (a) BC similarity 를 cluster 순으로 정렬한 heatmap 과 (b) $\hat{z}$ 위에 cluster label 을 색으로 입힌
 biplot 을 보인다.






Figure 5: Spectral clustering on BC similarity, $K = 2$.




(a) Biplot, $K = 3$




(b) BC heatmap, $K = 3$

Figure 6: Spectral clustering on BC similarity, $K = 3$.




(a) Biplot, $K = 4$




(b) BC heatmap, $K = 4$

Figure 7: Spectral clustering on BC similarity, $K = 4$.



(a) Biplot, $K = 5$



(b) BC heatmap, $K = 5$

Figure 8: Spectral clustering on BC similarity, $K = 5$.

5 todo

결과정당화. 실루엣 점수 / nested 구조 기준으로 나누고, 기존 문헌과 결과 연결해서 정당화 작업 할 예정입니다.

클러스터링 결과 반복해서 얻을 필요 있을지?

References