

0923 labmeeting

윤현석

September 22, 2025

1 motivation

- LSM은 network 구조에 대한 시각화가 용이한 대신에 edge 복원 능력에 비해서 triangle, k-star, edgewise shared partnership 과 같은 고차 구조에 대한 복원력이 떨어지는 단점이 있음.
- 이러한 단점은 LSM fitting 과정에서 node 와 node 간에 dyadic 한 연결성만을 고려하기 때문일 수 있음.
- 그렇다면 LSM 으로 하여금 dyadic 한 연결성 외에 고차 연결성까지 고려할 수 있게 해서 고차 구조에 대한 복원력을 향상시킬 수 있지 않을까?
- 고차 연결성을 고려하게 하기 위한 방안:
 - LSJM: latent space joint model - node 를 공유하는 multilayered network 를 하나의 동일한 latent vector 를 이용하여 설명하고자 하는 방법론. (Gollini and Murphy. (2014) 방법론에서 distance term 앞의 coefficient β_i 만 추가한 버전 사용.)
 - multilayered network: dyadic 한 연결성만을 가지는 adjacency matrix 이외에 여러 가지 node proximity 들을 이용해 node 간의 고차 연결성을 반영한 network 를 정의할 수 있다. 그리고 해당 network 를 원래의 network 에 추가해 multilayered network 를 만들 수 있다.

2 node proximity

node 간의 path를 이용하여 정의된 node 간의 '유사성'

2.1 katz distance

- Katz (1953)
- Katz similarity: $T = aC + a^2C^2 + \dots + a^kC^k + \dots = (I - aC)^{-1} - I$
 - C : adjacency matrix - transition matrix
 - a : decay parameter
 - * C 의 biggest eigenvalue $\lambda_k < \frac{1}{a}$ 이어야 수렴한다.
- T_{ij} : node i, j 간 연결된 모든 길이의 walk 들을 그 길이에 따라 가중치를 매겨서 합한 값.
- edge 는 이미 주어진 것으로 간주하고 이와 별개로 node i,j 간의 proximity 를 구한다.

2.2 communicability

- Estrada and Hatano. (2008)
- communicability: $G_{pq} = \sum_{k=0}^{\infty} \frac{(A^k)_{pq}}{k!}$
 - A : adjacency matrix - transition matrix
 - graph spectrum 으로 다음과 같이 다시 나타낼 수 있다.
$$G_{pq} = \sum_{j=1}^n \phi_j(p)\phi_j(q)e^{\lambda_j}$$
 - ϕ : eigenvector, λ : eigenvalue of adjacency matrix.
- 위와는 다르게 decay parameter 사용할 필요 없다.
- 직관적으로 Katz similarity 와 유사하지만 communicability 의 경우 green function 과 동치라는 점에서 열역학에서 이야기하는 열 전달 메커니즘으로 node 간의 관계를 설명할 수 있음

2.3 resistance distance

- Klein and Randić (1993)
- resistance distance: $\Omega_{ab} = v_a - v_b = i_{ab} \cdot r_{ab} = I(a - b|L^+|a - b) = (a - b)^T L^+ (a - b)$
 - 해당 접근은 Network 를 전류가 흐르는 system 이라고 간주하므로 ohm's law 를 사용한다.
 - ohm's law: $\frac{v_x - v_y}{r_{xy}} = i_{xy} = \frac{I}{r_{xy}}(x - y|L^+|a - b) = \frac{I}{r_{xy}}(x - y)^T L^+ (a - b)$

- v_a : a node 의 전압
- r_{ab} : node a,b 를 잇는 간선의 저항 - 기본적으로 주어져 있다고
- i_{ab} : node a,b 를 오가는 전류량
- L^+ : moore - penrose inverse matrix of graph laplacian L
 - * $L = D - W$
 - * D 는 diagonal element 에 각 node 에 degree 가 들어가 있는 diagonal matrix
 - * W 는 adjacency matrix
- 그리고 해당 paper 의 lemma A 를 이용하여 i_{xy} 와 r_{xy} 간의 관계가 정의된다.

$$i_{xy} = \frac{I}{r_{xy}}(x - y)^T L^+(a - b)$$

여기서 a, b는 xy 가 속한 subgraph 의 두 정점으로 전류가 나가고 들어오는 지점을 의미한다.

- 따라서 Ω_{ab} 로 정의되는 resistance distance 는 a, b 사이의 전류의 이동이 얼마나 '수월한가' 에 영향을 받는다. 이는 정점간 가능한 연결 방법이 얼마나 많은가에 직접적으로 영향을 받는다.
- 위의 두 방법론과 다른 점은 해당 proximity 은 distance function 임을 증명할 수 있다는 점이다.
- 그러나 이 경우도 edge 자체에 어떤 값을 새로이 할당한다기보다는 node 간의 거리를 새롭게 정의한 것에 가깝다.

3 Model: LSJM using binary network & communicability distance

3.1 Data and Latent Geometry

Let $G = (V, E)$ be an undirected network on $n = |V|$ nodes. We observe two symmetric $n \times n$ matrices (zero diagonal):

$$Y_{ij}^{(1)} \in \{0, 1\} \quad (\text{binary layer}), \quad Y_{ij}^{(2)} > 0 \quad (\text{continuous layer; e.g., communicability distance}).$$

Each node i has a d -dimensional latent position $z_i \in \mathbb{R}^d$ and Euclidean pairwise distances

$$D_{ij} \equiv \|z_i - z_j\|_2, \quad i \neq j.$$

3.2 Layer-wise Likelihoods

Binary layer (logistic LSM). With layer-specific intercept α_1 and distance-slope $\beta_1 > 0$,

$$\eta_{ij}^{(1)} = \alpha_1 - \beta_1 D_{ij}, \quad \Pr(Y_{ij}^{(1)} = 1 \mid z, \alpha_1, \beta_1) = \text{logit}^{-1}(\eta_{ij}^{(1)}).$$

Hence the binary log-likelihood is

$$\ell_1(z, \alpha_1, \beta_1; Y^{(1)}) = \sum_{i < j} \left\{ Y_{ij}^{(1)} \log \pi_{ij} + (1 - Y_{ij}^{(1)}) \log(1 - \pi_{ij}) \right\},$$

where $\pi_{ij} = \text{logit}^{-1}(\alpha_1 - \beta_1 D_{ij})$.

Continuous layer (log-normal regression on distance). For the continuous layer, the code implements a log-normal observation model whose mean on the natural (not log) scale is $\exp(\eta_{ij}^{(2)})$. Specifically, with parameters $(\alpha_2, \beta_2, \kappa_2)$ and

$$\eta_{ij}^{(2)} = \alpha_2 + \beta_2 D_{ij} \quad (\text{note the "+" sign, suitable for distances such as communicability distance}),$$

we set

$$Y_{ij}^{(2)} \mid z, \alpha_2, \beta_2, \kappa_2 \sim \text{LogNormal}(\mu_{ij}, \sigma^2), \quad \mu_{ij} = \eta_{ij}^{(2)} - \frac{\kappa_2}{2}, \quad \sigma^2 = \kappa_2,$$

(gamma 에 비해 직관적으로 Parameter 조절이 수월하기 때문에 선택.)

so that $\mathbb{E}[Y_{ij}^{(2)} \mid z, \alpha_2, \beta_2, \kappa_2] = \exp(\eta_{ij}^{(2)})$. The continuous-layer log-likelihood is therefore

$$\ell_2(z, \alpha_2, \beta_2, \kappa_2; Y^{(2)}) = \sum_{i < j} \left\{ -\frac{1}{2} \log(2\pi\kappa_2) - \log Y_{ij}^{(2)} - \frac{\left(\log Y_{ij}^{(2)} - \alpha_2 - \beta_2 D_{ij} + \frac{\kappa_2}{2} \right)^2}{2\kappa_2} \right\}.$$

3.3 Priors and Hyperpriors

3.3.0.1 Latent positions. Each z_i has an isotropic Gaussian prior with fixed variance $\sigma^2 > 0$ (shared across layers):

$$z_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}_d(0, \sigma^2 I_d).$$

3.3.0.2 Intercept hierarchy (per layer $\ell \in \{1, 2\}$).

$$\alpha_\ell \mid \xi_\ell, \psi_\ell^2 \sim \mathcal{N}(\xi_\ell, \psi_\ell^2), \quad \xi_\ell \sim \mathcal{N}(m_{0\ell}, \kappa_{0\ell}), \quad \psi_\ell^2 \sim \text{Inv-Gamma}(\alpha_{0\ell}, \beta_{0\ell}).$$

Remark. In this code there is one α_ℓ per layer (so effectively a single “observation” in the α -hierarchy); the Gibbs updates reduce to the $n_\ell = 1$ case.

3.3.0.3 Distance slopes. Two options are coded; the active one in the main loop uses a *log-normal prior* via $\phi_\ell = \log \beta_\ell$:

$$\underbrace{\phi_\ell}_{\log \beta_\ell} \sim \mathcal{N}(\mu_{\phi\ell}, s_{\phi\ell}^2) \iff \beta_\ell \sim \text{LogNormal}(\mu_{\phi\ell}, s_{\phi\ell}^2).$$

(샘플러 본문에서는 $\mu_{\phi\ell} = 0$, $s_{\phi\ell}^2 = 1$ 로 사용됨.)

또한 (주석 처리된) 대안으로 감마 사전분포도 구현되어 있습니다:

$$\beta_\ell \sim \text{Gamma}(a_{0\ell}, b_{0\ell}) \quad (\text{shape-rate parameterization}).$$

3.3.0.4 Log-normal variance (continuous layer).

$$\log \kappa_2 \sim \mathcal{N}(m_\kappa, s_\kappa).$$

이는 κ_2 에 대한 로그-정규 사전분포와 동일하며, 밀도에 야코비안 $-\log \kappa_2$ 가 포함됩니다.

3.4 Posterior (up to a constant)

Let $\theta = \{z_{1:n}, \alpha_1, \beta_1, \xi_1, \psi_1^2, \alpha_2, \beta_2, \kappa_2, \xi_2, \psi_2^2\}$. With independence assumptions as above and using only $i < j$ pairs,

$$\begin{aligned} \log p(\theta \mid Y^{(1)}, Y^{(2)}) &\propto \ell_1(z, \alpha_1, \beta_1; Y^{(1)}) + \ell_2(z, \alpha_2, \beta_2, \kappa_2; Y^{(2)}) - \frac{1}{2\sigma^2} \sum_{i=1}^n \|z_i\|_2^2 \\ &+ \sum_{\ell=1}^2 \log \mathcal{N}(\alpha_\ell \mid \xi_\ell, \psi_\ell^2) + \sum_{\ell=1}^2 \left(\log \mathcal{N}(\xi_\ell \mid m_{0\ell}, \kappa_{0\ell}) + \log \text{IG}(\psi_\ell^2 \mid \alpha_{0\ell}, \beta_{0\ell}) \right) \\ &+ \begin{cases} \sum_{\ell=1}^2 \log \mathcal{N}(\phi_\ell \mid \mu_{\phi\ell}, s_{\phi\ell}^2) & (\text{활성: } \phi_\ell = \log \beta_\ell) \\ \sum_{\ell=1}^2 \log \text{Gamma}(\beta_\ell \mid a_{0\ell}, b_{0\ell}) & (\text{대안: 감마 prior}) \end{cases} + \log \mathcal{N}(\log \kappa_2 \mid m_\kappa, s_\kappa). \end{aligned}$$

3.5 Bayesian Inference (MCMC)

The code runs a Metropolis-within-Gibbs sampler with single-site MH updates for z and RW proposals for layer parameters. Let $\mathcal{U}$ denote the set $\{(i, j) : i < j\}$.

(A) Update latent positions z (single-site MH). For $j = 1, \dots, n$ propose

$$z'_j = z_j + \epsilon, \quad \epsilon \sim \mathcal{N}_d(0, \text{diag}(\text{prop_}z^2)).$$

Accept with probability $\min\{1, \exp(\Delta)\}$ where

$$\Delta = \left[\ell_1(z', \alpha_1, \beta_1; Y^{(1)}) - \ell_1(z, \alpha_1, \beta_1; Y^{(1)}) \right] + \left[\ell_2(z', \alpha_2, \beta_2, \kappa_2; Y^{(2)}) - \ell_2(z, \alpha_2, \beta_2, \kappa_2; Y^{(2)}) \right] - \frac{\|z'_j\|_2^2 - \|z_j\|_2^2}{2\sigma^2}.$$

(B) Update intercepts α_ℓ (RW-Normal MH). Propose $\alpha'_\ell = \alpha_\ell + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \text{prop_}\alpha_\ell^2)$. Accept with probability based on the symmetric-RW MH ratio:

$$\Delta_\ell = \left[\ell_\ell(\alpha'_\ell) - \ell_\ell(\alpha_\ell) \right] + \log \mathcal{N}(\alpha'_\ell \mid \xi_\ell, \psi_\ell^2) - \log \mathcal{N}(\alpha_\ell \mid \xi_\ell, \psi_\ell^2).$$

(C) Update slopes via log-parameterization Let $\phi_\ell = \log \beta_\ell$. Propose $\phi'_\ell = \phi_\ell + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \text{prop_}\beta_\ell^2)$ (symmetric). Accept with probability

$$\Delta_\ell = \left[\ell_\ell(\beta'_\ell = e^{\phi'_\ell}) - \ell_\ell(\beta_\ell = e^{\phi_\ell}) \right] + \log \mathcal{N}(\phi'_\ell \mid \mu_{\phi_\ell}, s_{\phi_\ell}^2) - \log \mathcal{N}(\phi_\ell \mid \mu_{\phi_\ell}, s_{\phi_\ell}^2).$$

(제안은 ϕ -공간에서 대칭이므로 헤이스팅스 보정이 불필요합니다.)

(D) Update log-normal variance κ_2 (log-RW MH). Propose in log-space: $\log \kappa'_2 = \log \kappa_2 + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \text{prop_}\kappa^2)$. Accept with

$$\Delta = \left[\ell_2(\kappa'_2) - \ell_2(\kappa_2) \right] + \left\{ \log \mathcal{N}(\log \kappa'_2 \mid m_\kappa, s_\kappa) - \log \mathcal{N}(\log \kappa_2 \mid m_\kappa, s_\kappa) \right\} + (\log \kappa'_2 - \log \kappa_2),$$

where the last term is the Hastings correction for the log-space proposal.

(E) Hyperparameters (ξ_ℓ, ψ_ℓ^2) (Gibbs). With one α_ℓ per layer, the normal-normal and IG conjugacy yield

$$\xi_\ell \mid \alpha_\ell, \psi_\ell^2 \sim \mathcal{N}(m_{n\ell}, \kappa_{n\ell}), \quad \kappa_{n\ell} = \left(\frac{1}{\psi_\ell^2} + \frac{1}{\kappa_{0\ell}} \right)^{-1}, \quad m_{n\ell} = \kappa_{n\ell} \left(\frac{m_{0\ell}}{\kappa_{0\ell}} + \frac{\alpha_\ell}{\psi_\ell^2} \right),$$

$$\psi_\ell^2 \mid \alpha_\ell, \xi_\ell \sim \text{Inv-Gamma}(\alpha_{0\ell} + \frac{1}{2}, \beta_{0\ell} + \frac{1}{2}(\alpha_\ell - \xi_\ell)^2).$$

3.6 Identifiability and Post-processing

The latent space is invariant to rigid motions (translation, rotation, reflection). The prior centers z_i at 0 but rotational/reflectional non-identifiability remains. After sampling, the code aligns all saved z -draws to the MAP (by joint objective) configuration via Procrustes matching *without scaling*. This yields comparable latent coordinates across MCMC iterations.

3.7 결과

3.7.1 communicability & communicability distance & binary

```
1 > fit$accept
2 $z
3 [1] 0.6310 0.6188 0.6090 0.5844 0.4180 0.4112 0.4246 0.5978 0.5944 0.5778 0.4118
   0.5982 0.5764 0.5918 0.3964 0.3810 0.6054 0.5140 0.3964 0.5896
4 [21] 0.3836 0.5160 0.3918 0.5790 0.4806 0.4974 0.5858 0.5972 0.5876 0.5626 0.6092
   0.6270 0.6240 0.6138
5
6 $alpha_bin
7 [1] 0.5478
8
9 $beta_bin
10 [1] 0.649
11
12 $alpha_comm
13 [1] 0.2404
14
15 $beta_comm
16 [1] 0.534
17
18 $kappa_comm
19 [1] 0.2898
20
21 $alpha_cdist
22 [1] 0.2096
23
24 $beta_cdist
25 [1] 0.2316
26
```

```
27 $kappa_cdist
28 [1] 0.338
```




Figure 1: traceplot




Figure 2: Comparison of latent position


다른 network 구조들이 masking 되는 이유는?

3.7.2 katz index & binary


communicability 와 다른 점 - α 값의 조정을 통해서 국소적인 연결성에서 전역적 연결성 중 어느 쪽을 강조할지 선택할 수 있음. α 의 값이 작아질수록 국소적인 연결성을 강조할 수 있음.

마지막은 dyad 만 고려한 원래의 LSM 결과와 매우 유사합니다.


전역적인 연결성을 강조한 layer 를 추가한 상태로 LSJM 을 구현해 보았습니다.




(a) $\alpha' = \text{maximum}\{\alpha\} * 0.9$



(b) $\alpha' = \text{maximum}\{\alpha\} * 0.8$



(c) $\alpha' = \text{maximum}\{\alpha\} * 0.1$



(d) $\alpha' = \text{maximum}\{\alpha\} * 0.05$

Figure 3: latent position visualization

```

1 > fit$accept
2 $z
3 [1] 0.1850 0.2692 0.2602 0.3420 0.4630 0.3992 0.3978 0.4210 0.4120 0.5842 0.4680
   0.6218 0.5512 0.3932 0.5664 0.5682 0.4976 0.5486 0.5746 0.5230
4 [21] 0.5706 0.5518 0.5782 0.3934 0.4542 0.4598 0.5440 0.4648 0.5258 0.4342 0.4522
   0.3706 0.2242 0.1750
5
6 $alpha1
7 [1] 0.4514
8
9 $beta1
10 [1] 0.1112
11
12 $alpha2
13 [1] 0.4384
14

```

```

15 $beta2
16 [1] 0.6746
17
18 $kappa2
19 [1] 0.4836

```




Figure 4: traceplot

3.8 구현상의 난점

3.8.1 β_i 의 수렴이 어려움 & network layer 별 영향력의 불균형

$$\eta_{i,j}^{(\ell)} = \alpha_\ell \beta_\ell \cdot d(z_i, z_j)$$

에서 β_ℓ 의 수렴이 어렵고, 쉽게 하나의 layer에 값이 쏠리는 현상이 생깁니다.

실제로 하나의 layer가 다른 모든 network의 구조를 다 설명해버렸다고도 볼 수 있지만, 시각화를 해서 보면 군집 구조를 완전히 반영하지 못하는 등의 문제가 있습니다.

왜 이러한 쏠림이 생기는지 확인 중에 있습니다.

References

- Estrada, E. and N. Hatano. (2008). Communicability in complex networks. *Physical Review E*.
- Gollini, I. and T. B. Murphy. (2014). Joint modelling of multiple network views. *Taylor and Francis*.
- Katz, L. (1953). A new status index derived from sociometric analysis. *Psychometrika*.
- Klein, D. J. and M. Randić (1993). Resistance distance. *Journal of Mathematical Chemistry*.