

1104 labmeeting

윤현석

November 10, 2025

1 previous

연구의 목표 살짝 변경.

추가적인 정보를 더 주는 건 맞는데, 그 정보의 data type 이 continuous 하기 때문에 정보량 차이가 발생하는 문제를 해결해야 함.

결론적으로는 이 과정을 통해서 LSM 의 고차 구조 복원을 더 잘 해보도록 하겠다는 것.

2 model description

Sosa (2022) 의 논문에서 제안한 구조를 생각해 보았습니다.

$$g_{(\ell)}(Pr(Y_{ij} = y_{ij})) = \alpha^{(\ell)} + \theta_i^{(\ell)} + \theta_j^{(\ell)} - \beta^{(\ell)} d(u_i^{(\ell)}, u_j^{(\ell)})$$

$$u_i^{(\ell)} | z_i \sim N(z_i, I \cdot \sigma_\ell^2)$$

의 형태로 global latent position 과 layer specific latent position 을 분리한다.

이런 식으로 모델링하면 binary/continuous network 의 likelihood 가 함께 계산되지 않으므로 masking 문제를 다소 해결할 수 있지 않을까?

이 모델에서 걱정해야 하는 것. (예상)

- global pattern 이 유의미하게 나와야 함. layer 별 latent position 이 따로 놓고 global latent position 이 원점에 모여서 아무 역할을 하지 못하면 안됨.
 - 개별 layer 의 latent position 과 global position 이 멀리 떨어지지 못하게 하는 penalty 혹은 prior 를 사용해야 할 것 같습니다.

- binary layer 의 latent position 이 global latent position pattern 을 통해서 continuous layer 의 latent position 정보를 충분히 얻어야 함.
 - global pattern 이 유의미하게 나오고, continuous pattern 이 global pattern 과 지나치게 떨어지지 않으면 될 것 같다는 생각.
- 특정 latent position 이 다른 latent position 과 global latent position 을 지나치게 끌어당기면 안 됨.
 - 개별 layer 의 likelihood 의 영향이 직접적으로 다른 layer 의 Latent position 에 전달되지 않고, global latent position 을 통해 전달되기 때문에 어느 정도 해결될 것으로 기대함.
 - 만약 계속 문제가 생기면 다시 돌아와서 해결 방안 고민해 볼 듯 합니다.

결론적으로 상대적으로 이질적인 구조의 network 형태에서도 global pattern 을 어느 정도 파악하고, 개별 layer 에도 해당 정보를 전달할 수 있는 모델이어야 한다는 필요가 있습니다.

예를 들어 binary - global - continuos 이렇게 있으면 global pattern 이 어느 정도 중간 지점을 잘 찾아 들어가야 한다는 의미가 될 것 같습니다.

2.1 main model

$$g_{(\ell)}(Pr(Y_{ij} = y_{ij})) = \alpha^{(\ell)} + \theta_i^{(\ell)} + \theta_j^{(\ell)} - \beta^{(\ell)} d(u_i^{(\ell)}, u_j^{(\ell)})$$

$$u_i^{(\ell)} | z_i \sim N(z_i, I \cdot \sigma_{(\ell)}^2)$$

형태에서 global latent position 을 이용한 euclidean distance matrix 를 $D^{(0)}$ 라고 하고 ℓ th latent position 을 이용한 euclidean distance matrix 를 $D^{(\ell)}$ 이라고 하겠습니다. 이 때 아래와 같이 penalty term 을 정의할 수 있지 않을까요?

2.1.1 Normalized Frobenius norm-based penalty

$$\mathcal{R}_F^{(\ell)} = \lambda_F^{(\ell)} \left\| \frac{D^{(\ell)}}{\|D^{(\ell)}\|_F} - \frac{D^{(0)}}{\|D^{(0)}\|_F} \right\|_F^2$$

단순히 distance matrix 들이 실제로 얼마나 달라졌는가? 를 기준으로 거리 산정.

2.1.2 Spectral norm-based penalty

$$\mathcal{R}_{\text{spec}}^{(\ell)} = \lambda_{\text{spec}}^{(\ell)} \left(\|D^{(\ell)} - D^{(0)}\|_2 \right)^2 \quad \text{or} \quad \lambda_{\text{spec}}^{(\ell)} \left(\|D^{(\ell)}\|_2 - \|D^{(0)}\|_2 \right)^2$$

첫 번째는 distance matrix 의 shape deviation 자체에 대해서 penalty 를 준 것 - 차이를 matrix 로 만든 form 의 가장 큰 singular value 를 구하는 것이므로. 두 번째는 각 distance matrix 간의 shape 차이에 대해서 penalty 를 준 것.

2.1.3 Nuclear norm-based penalty

$$\mathcal{R}_{\text{nuc}}^{(\ell)} = \lambda_{\text{nuc}}^{(\ell)} \left(\|D^{(\ell)} - D^{(0)}\|_* \right) \quad \text{or} \quad \lambda_{\text{nuc}}^{(\ell)} \left(\|D^{(\ell)}\|_* - \|D^{(0)}\|_* \right)^2$$

MultiNeSS 논문에서 사용한 norm 가져와 보았습니다.. matrix 의 복잡도,,,와 관련한 norm 이라고 하는데,

첫 번째는 마찬가지로 차이의 복잡도 - 다양한 부분에서 차이가 나면 복잡도 올라갈 듯. 두 번째는 서로 간의 복잡도 차이 - 이 부분은 어떤 식으로 해석해야 할 지 아직 잘 모르겠습니다.

2.2 prior distribution

$$\alpha^{(\ell)} \sim \mathcal{N}(0, 1)$$

$$\theta_i^{(\ell)} \sim \mathcal{N}(0, 1)$$

해당 변수들은 일단 이렇게 됐는데, Sosa (2022) 에서는 모든 변수에 대해 계층적인 구조를 추가했다. (0,1 대신 normal, invgamma prior 를 부여한 변수 사용했다는 것.) 이는 모델의 유연성을 추가하긴 하지만, karate network 만을 사용하는 현재 상황에서는 적당히 hyperparameter setting 해서 해결할 수 있을 것으로 봐서 일단 skip 했음.

$$\beta^{(\ell)} \sim \text{Gamma}(a_0, b_0)$$

해당 변수는 non-negative 값을 가질 수 있도록 한다. Sosa (2022) 에서는 $\exp(\theta)$ 값으로 nonnegativity 를 지킴. 일단 딱히 바뀌야 할 이유를 찾지 못했고, exponential 은 기하급수적으로 커지는 성질 때문에 특정 layer 의 latent position 의 영향이 과대추정될까봐 일단 뺐음.

$$z_i \sim \mathcal{N}(0, 1)$$

로 고정하였음. latent position 의 경우 지나치게 유연하면 identifiability issue 가 더 심해질 것 같아서,,, 마지막으로 variance 관련 parameter 는 아래와 같이 정의했음.

$$\sigma_{(\ell)}^2 \sim \text{IG}(a_1, b_1)$$

2.3 update rule

let $\Theta_{ij}^{(\ell)} = \{\alpha^{(\ell)}, \theta_i^{(\ell)}, \theta_j^{(\ell)}, \beta^{(\ell)}, u_i^{(\ell)}, u_j^{(\ell)}\}$

2.3.1 update $\alpha^{(\ell)}$

with likelihood function:

$$\ell^{(\ell)}(\alpha^{(\ell)} | \Theta_{ij}^{(\ell)} \setminus \alpha^{(\ell)}) = \prod_{i < j} P_{(\ell)} \left(g_{(\ell)}^{-1} \left(\alpha^{(\ell)} + \theta_i^{(\ell)} + \theta_j^{(\ell)} - \beta^{(\ell)} d(u_i^{(\ell)}, u_j^{(\ell)}) \right) \right)$$

therefore, with symmetric proposal distribution - Normal - , MH ratio is,

$$\text{MH ratio} = \frac{P(\alpha^{(\ell)*}) \ell^{(\ell)}(\alpha^{(\ell)*} | \Theta_{ij}^{(\ell)} \setminus \alpha^{(\ell)})}{P(\alpha^{(\ell)}) \ell^{(\ell)}(\alpha^{(\ell)} | \Theta_{ij}^{(\ell)} \setminus \alpha^{(\ell)})}$$

such that $\alpha^{(\ell)*}$ is proposed parameter.

2.3.2 update $\theta_i^{(\ell)}$

with likelihood function:

$$\ell^{(\ell)}(\theta_i^{(\ell)} | \Theta_{ij}^{(\ell)} \setminus \theta_i^{(\ell)}) = \prod_{i < j} P_{(\ell)} \left(g_{(\ell)}^{-1} \left(\alpha^{(\ell)} + \theta_i^{(\ell)} + \theta_j^{(\ell)} - \beta^{(\ell)} d(u_i^{(\ell)}, u_j^{(\ell)}) \right) \right)$$

therefore, with symmetric prior distribution - Normal - , MH ratio is,

$$\text{MH ratio} = \frac{P(\theta_i^{(\ell)*}) \ell^{(\ell)}(\theta_i^{(\ell)*} | \Theta_{ij}^{(\ell)} \setminus \theta_i^{(\ell)*})}{P(\theta_i^{(\ell)}) \ell^{(\ell)}(\theta_i^{(\ell)} | \Theta_{ij}^{(\ell)} \setminus \theta_i^{(\ell)})}$$

such that $\theta_i^{(\ell)*}$ is proposed parameter.

2.3.3 update $\beta^{(\ell)}$

with likelihood function same as above, and using normal distribuiton as proposal distribution, we have to use jacobian due to parameter transition for nonnegative restriction.

let $\log \beta^{(\ell)} = \kappa^{(\ell)}$, therefore jacobian is $\beta = \frac{d\beta^{(\ell)}}{d\kappa^{(\ell)}}$. So the MH ratio is defined as follow,

$$\text{MH ratio} = \frac{P(\beta^{(\ell)*}) \ell^{(\ell)}(\beta^{(\ell)*} | \Theta_{ij}^{(\ell)} \setminus \beta^{(\ell)*}) \beta^{(\ell)*}}{P(\beta^{(\ell)}) \ell^{(\ell)}(\beta^{(\ell)} | \Theta_{ij}^{(\ell)} \setminus \beta^{(\ell)}) \beta^{(\ell)}}$$

such that $\beta^{(\ell)*}$ is proposed parameter.

2.3.4 **update** $u_i^{(\ell)}$

2.3.5 **update** $z_i^{(\ell)}$

References

Sosa, Juan. Betancourt, B. (2022). A latent space model for multilayer network data. *Computational Statistics & Data Analysis*.