

Year-end Research: multilayered LSIRM for Mixed-Type item - response data

Hyunseok Yoon

Yonsei University

January 5, 2026

① Model Summary

- multilayered LSIRM for Mixed-Type item - response data
- simulation study
- real data example

② 차년도 연구 계획 / 목표

Model Summary

multilayered LSIRM for Mixed-Type item - response data

LSIRM

$$\text{logit}(\mathbb{P}(Y_{i,j}|\alpha_j, \beta_i, a_j, b_i)) = \alpha_j + \beta_i - \gamma d(a_j, b_i)$$

- $Y_{i,j}$: node i, j 간의 edge (IRT에서는 j 번째 피험자가 i 번째 item에 올바르게 - 혹은 의도한 바 대로 응답하는 사건을 의미하는 확률변수)
- α_j, β_i : node j, i 의 특성 (IRT에서는 a_j - j 번째 피험자의 ability, b_i - i 번째 item의 difficulty)
- a_j, b_i : node j, i 의 latent vector - 해당 vector들 간의 관계를 이용하여 network 상에서의 node의 상대적 위치를 mapping 한다.

Model Summary

multilayered LSIRM for Mixed-Type item - response data

LSIRM - IRT

$$\text{logit}(\mathbb{P}(Y_{i,j}|\alpha_j, \beta_i, a_j, b_i)) = \alpha_j + \beta_i - \gamma d(a_j, b_i)$$

- LSIRM 은 item response data 의 응답 패턴을 아래와 같이 모델링합니다.
 - Y_{ij} : i 번째 피험자가 j 번째 item 에 응답하는 사건의 random variable
 - a_j - j 번째 피험자의 ability
 - b_i - i 번째 item 의 difficulty
- IRT 는 특정 피험자가 특정 문항에 응답할 확률을 피험자의 능력 / 문항의 난이도의 조합으로 설명합니다.
- LSIRM 은 두 요소 외에 문항 응답 확률에 영향을 미치는 요소를 문항과 피험자 간의 잠재적인 상호작용으로 설명합니다.
 - $\gamma d(a_j, b_i)$

Model Summary

multilayered LSIRM for Mixed-Type item - response data

LSIRM - network model

$$\text{logit}(\mathbb{P}(Y_{i,j}|\alpha_j, \beta_i, a_j, b_i)) = \alpha_j + \beta_i - \gamma d(a_j, b_i)$$

- LSIRM 은 설문지 데이터를 item, respondent 로 이루어진 bipartite network 로 간주합니다.
 - node: item, respondent
 - edge: responses
- LSIRM 은 bipartite network 의 edge formation 확률을 아래와 같이 모델링합니다.
 - Y_{ij} : node i,j 간의 edge 가 형성되는 사건의 random variable
 - a_j, b_i - j 번째 respondent node, i 번째 item node 의 degree effect
 - IRT 는 network 의 edge formation 을 item/respondent 의 degree effect 로만 설명합니다.
 - LSIRM 은 두 요소 외의 node 간에 존재하는 잠재적인 상호작용을 추가로 이용해 edge formation 을 설명합니다.
 - $\gamma d(a_j, b_i)$

Model Summary

multilayered LSIRM for Mixed-Type item - response data

LSIRM - GLM

$$\text{logit}(\mathbb{P}(Y_{i,j}|\alpha_j, \beta_i, a_j, b_i)) = \alpha_j + \beta_i - \gamma d(a_j, b_i)$$

- LSIRM 은 random variable Y_{ij} 를 GLM framework 를 이용해서 모델링 합니다.
- 따라서 적절한 link function 과 data 에 대한 분포 가정만 있다면 Y_{ij} 가 반드시 binary random variable 일 필요는 없습니다.

Model Summary

multilayered LSIRM for Mixed-Type item - response data

sammel(1997)

$$g_m(\mu_{im}) = \eta_{im} = \mathbf{x}_{im}^\top \boldsymbol{\beta}_m + \lambda_m^\top \mathbf{b}_i, \quad \mathbf{b}_i \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}).$$

Sammel (1997)은 exponential family 에 속하는 data 를 위와 같이 모델링합니다.

한 개인 $i = 1, \dots, N$ 과 지표 $m = 1, \dots, M$ 에 대해

- $g_m(\cdot)$ 는 data type 별 link function
- $\mathbf{x}_{im}$: covariate
- $\boldsymbol{\beta}_m$: 지표 별 coefficient
- $\boldsymbol{\lambda}_m$: latent factor 의 loading
- $\mathbf{b}_i$: 개인 별 latent factor

Model Summary

multilayered LSIRM for Mixed-Type item - response data

LSIRM - multilayered

$$\eta_{ij}^{(\ell)} = \alpha_i + \beta_j^{(\ell)} - \gamma D_{ij}^{(\ell)}, \quad \ell \in \{1, 2, 3\}.$$

- $\eta_{ij}^{(\ell)}$: ℓ 번째 data type 으로 이루어진 설문지 data - ℓ 번째 bipartite network 의 edge formation 확률을 모델링하는 선형식
- α_i : i 번째 피험자의 ability
- $\beta_j^{(\ell)}$: ℓ 번째 data type 을 가지는 j 번째 item 의 difficulty
- $D_{ij}^{(\ell)}$: ℓ 번째 data type 을 가지는 j 번째 item 과 i 번째 피험자의 상호작용
- $D_{ij}^{(\ell)} = d(a_i, b_j^{(\ell)})$: L2 distance
- γ : 전체 설문지 데이터에서 latent vector 간의 상호작용이 미치는 영향력 정도

Model Summary

multilayered LSIRM for Mixed-Type item - response data

layer 1: binary data

$$Y_{ij}^{(1)} \mid \eta_{ij}^{(1)} \sim \text{Bernoulli}(p_{ij}), \quad p_{ij} = \text{logit}^{-1}(\eta_{ij}^{(1)}).$$

layer 2: continuous data

$$Y_{ij}^{(2)} \mid \eta_{ij}^{(2)}, \sigma_0^2 \sim \mathcal{N}(\eta_{ij}^{(2)}, \sigma_0^2),$$

layer 3: count data

$$Y_{ij}^{(3)} \mid \mu_{ij}, \kappa \sim \text{NB}\left(\text{size} = \frac{1}{\kappa}, \text{mean} = \mu_{ij}\right), \quad \kappa > 0.$$

with $\mu_{ij} = \exp(\eta_{ij}^{(3)})$.

Model Summary

multilayered LSIRM for Mixed-Type item - response data

- 기존 LSIRM 은 mixed type data 가 있는 경우 하나의 data type 으로 통일하는 과정이 필요합니다.
- 보통의 경우 binary 화 하게 되는데, (binary data 를 continuous data 로 변환하기는 곤란하므로)
- 이 경우 원래 data 가 가지고 있는 관계에 대한 추정이 biased 될 가능성이 있습니다.
 - 5 점 likert 척도를 예로 들면, 응답 패턴이 1/3/5 세 군집으로 나뉘었을 때 별도 처리를 하지 않고 학습했을 때 3으로 응답한 패턴을 잡아내지 못한다거나,
 - count 응답을 받는 척도를 예로 들면, 응답 패턴이 0/1 로만 구분하기 어려운 경우를 상상해 볼 수 있습니다.
 - 이 경우 item - response 간의 geometry 가 왜곡될 수 있습니다.

Model Summary

simulation study

- standard LSIRM 이 node 간의 geometrical structure 를 잘 잡아내지 못할 것 같은 시나리오를 설정하여 simulation 을 해 보았습니다.
- setting:
 - respondent 군집: 3 - 나란히 할당
 - item 군집: 3 - respondent 군집과 동일한 방향으로 나란히 할당
 - respondent 군집과 item 군집의 거리 관계가 명확하게 분리되지 않고, 하나의 item 에 대해서 각 respondent 가 가지는 거리 관계를 최대한 연속적으로 가질 수 있도록 배치하였습니다.
 - item 과 respondent 의 latent position 간 거리 관계가 연속적인 경우 (binary 하게 구분하기 곤란한 경우) binary 한 데이터만으로는 latent position 의 structure 를 복원하기 어려울 수 있다고 생각했습니다.


Model Summary

simulation study

2개 모델 모두 수렴은 잘 되었으나 standard lsirm 의 경우 continuous/count item 에 대한 몇 개의 beta 값과, alpha 의 variance 값을 복원하지 못했습니다.


Model Summary

simulation study - latent position 비교




Model Summary

simulation study - latent position 비교



Model Summary

simulation study - latent position 비교



Model Summary

simulation study


수치적으로 비교하기 위해, 각 item 별로 respondent 와의 distance 를 구해서 true position 에서 얻은 distance 와의 correlation 을 비교해 보았습니다.

- multilayered LSIRM
 - All layers ($n \times 30$): 0.838
 - Binary layer ($n \times 10$): 0.825
 - Likert layer ($n \times 10$): 0.853
 - Count layer ($n \times 10$): 0.843
- LSIRM
 - All layers ($n \times 30$): 0.797
 - Binary layer ($n \times 10$): 0.785
 - Likert layer ($n \times 10$): 0.815
 - Count layer ($n \times 10$): 0.795


Model Summary

simulation study

Distance recovery: multilayered LSIRM



Distance recovery: LSIRM



시각적으로 true distance 와 estimated distance 를 scatterplot 으로 확인해 보았습니다. 전반적으로 거리가 멀어질수록 LSIRM 이 true 값에 비해 distance 를 과대추정하는 것으로 보입니다.

Model Summary

KSHA data


현재 KSHA data 를 이용하여 multilayered LSIRM 을 추정하고 있습니다.

- binary data 중 가족 구성원 동거 여부/bully/victim 제거
- 공선성 피하기 위하여 count data 중 평일/주말 수면시간/공부시간 항목 중 평일 - 수면시간만 사용(수면시간/사교육 시간 사용)
- 마찬가지로 hierarchical 한 구조 제거한 후에 multilayered LSIRM fitting 했습니다.

Model Summary

KSHA data


현재 KSHA data 를 이용하여 multilayered LSIRM 을 추정하고 있습니다.



Model Summary

KSHA data

현재 KSHA data 를 이용하여 multilayered LSIRM 을 추정하고 있습니다.



차년도 연구 계획 / 목표

연구 계획

① 이후 과제

- ① simulation study 에서 multilayered LSIRM 이 더 강점을 가지는 case 를 찾아 봐야 할 것 같습니다.
- ② 현재는 ordinal data 를 normal distribution 을 이용하여 continuous data 로 보고 있는데, 이를 ordinal data 로 threshold 를 이용하여 modeling 해야 할 것 같습니다. (simulation 상황에서 true 값 cover 못 하는 중 - continuous data 로 sampling → ordinal 로 변환 → continuous 로 fitting 하는 과정에서)
- ③ KSHA data 를 이용하여 real data analysis 하고 있는데, 이 부분에서 multilayered LSIRM 을 통해서 새롭게 얻을 수 있는 인사이트가 있을지 확인해야 할 것 같습니다. 이 부분은 염유식 교수님 랩실 분들과 미팅 요청해야 할 것 같습니다.

② 위의 과제와 병행하여 methodology 위주로 model 정리 중에 있습니다.