

A Multilayered LSIRM Approach to Phenotype Clustering

Hyunseok Yoon

Yonsei University

May 4, 2026

- 1 introduction
- 2 multilayered LSIRM
- 3 bayesian factor - mixture clustering
- 4 simulation study
- 5 real data analysis - MIDUS wave 2 / refresher 1

multilayered LSIRM application approach 로써 phenotype clustering task 을 선정하였음

phenotype

shen(2017): observable characteristics and clinical traits of diseases and organisms.

multilayered LSIRM 을 이용하여 서로 다른 data type 을 가지는 item 들에 대한 respondent 들의 응답/반응을 기준으로 clustering 함으로써 phenotype 정의에 사용할 수 있는 통계적 근거 마련이 가능.

phenotype clustering 을 위하여 LSIRM 결과를 사용하는 probabilistic PCA based latent factor mixture clustering model 을 이용함.


- ① 개별 item 들이 respondent 에 대해 가지고 있는 거리관계를 벡터화
- ② 이를 행렬로 만든 객체에 대하여 probabilistic PCA(PPCA)를 진행
- ③ PPCA 결과로 얻어진 개별 item 의 factor score 에 gaussian mixture prior 를 설정하여 개별 factor score 의 cluster membership 을 결정.

remark

- multilayered LSIRM 와 PPCA based latent factor mixture clustering model 은 하나의 MCMC sampling flow 를 가지지만 joint model 은 아님.
- LSIRM 의 latent position 의 posterior distribution 을 활용한 post - hoc clustering method.

modeling overview

LSIRM result




Respondent profile

Respondent profile						
	j=1	j=2	j=3	j=4	...	j=n
i=1						
i=2						
i=3						
...						
i=p						

PPCA

Clustering with gaussian mixture



- latent position 으로 직접 clustering 하지 않는 이유?
- layer 별 item - respondent 의 distance 의미가 다르기 때문. (link function / data type 이 다르므로)
- 따라서 layer 간 공유하는 respondent position 상에서 '상대적으로 어떤 위치에 존재하는가'를 기준으로 item 들을 비교하고자 함.

multilayered LSIRM

mixed - type item response dataset 을 multilayered network 로 간주하여 하나의 respondent latent position 과 여러 개의 item latent position 의 거리 관계로 응답을 설명하는 모델.

LSIRM (mixed-type, 4 layers)

$$\eta_{ij}^{(\ell)} = \alpha_i^{(\ell)} + \beta_j^{(\ell)} - \gamma^{(\ell)} D_{ij}^{(\ell)}, \quad D_{ij}^{(\ell)} = \|a_i - b_j^{(\ell)}\|_2.$$

- $\alpha_i^{(\ell)}$: layer ℓ 의 respondent i 의 ability
- $\beta_j^{(\ell)}$: layer ℓ 의 item j 의 difficulty
- $\gamma^{(\ell)}$: layer ℓ 의 ability 와 difficulty 외에 item 과 respondent 간 가지는 고차 관계가 model 에 일반적으로 영향 미치는 정도
- $D_{ij}^{(\ell)}$: layer ℓ 의 euclidean latent space 에서의 item, respondent 간의 거리 - 고차 관계 표현

Layer 1: binary

$$Y_{ij}^{(1)} \mid \eta_{ij}^{(1)} \sim \text{Bernoulli}\left(\text{logit}^{-1}\left(\eta_{ij}^{(1)}\right)\right)$$

위에서 계산한 $\eta_{ij}^{(\ell)}$ 는 layer 의 data 형태에 적합한 link function 과 distribution 가정 하에서 정의됨.

layer 1 의 경우 binary data 이므로 logit link 와 bernoulli distribution 가정을 사용한 logistic regression 의 형태를 가진다.

Layer 2: continuous (robust Student- t)

$$Y_{ij}^{(2)} \mid \eta_{ij}^{(2)}, \sigma_0^2, \lambda_{ij} \sim \mathcal{N}\left(\eta_{ij}^{(2)}, \sigma_0^2 / \lambda_{ij}\right), \quad \lambda_{ij} \sim \text{Gamma}(\nu_2/2, \nu_2/2)$$

Layer 3: count (Negative Binomial, per-item κ_j)

$$Y_{ij}^{(3)} \mid \mu_{ij}, \kappa_j \sim \text{NB}\left(\frac{1}{\kappa_j}, \mu_{ij}\right), \quad \mu_{ij} = \exp(\eta_{ij}^{(3)})$$

Layer 4: ordinal (GRM)

$$\text{logit } P(Y_{ij}^{(4)} \geq k) = \alpha_i^{(4)} + \beta_{jk}^{(4)} - \gamma^{(4)} D_{ij}^{(4)}, \quad k = 1, \dots, K_1 - 1$$

PPCA-based latent factor mixture clustering model

PPCA-FMC (item factor mixture clustering)

$$x_j = \log \|a_i - b_j^{(\ell)}\| \quad (\text{row-centered})$$

$$x_j \mid \delta, \Lambda, \eta_j, \sigma_\varepsilon^2 \sim \mathcal{N}_n(\delta + \Lambda \eta_j, \sigma_\varepsilon^2 I_n)$$

$$\eta_j \mid c_j = l \sim \mathcal{N}_r(\mu_l, \Sigma_l), \quad (\mu_l, \Sigma_l) \sim \text{NIW}(m_0, \kappa_0, \nu_0, S_0)$$

$$c_j \mid \rho \sim \text{Categorical}(\rho) \quad \rho \sim \text{Dirichlet}(e_0, \dots, e_0)$$

- profile 을 정규화하여 item 간의 repondent profile 의 상대적인 차이만을 확인하고자 함.
- 해당 작업이 하나의 MCMC chain 에서 돌아가지만 PPCA-FMC 의 정보는 LSIRM 적합에 영향을 미치지 않으므로 post - hoc 방법론임.

PPCA-based latent factor mixture clustering model

PPCA-FMC (item factor mixture clustering)

$$x_j = \log \|a_i - b_j^{(\ell)}\| \quad (\text{row-centered})$$

$$x_j \mid \delta, \Lambda, \eta_j, \sigma_\varepsilon^2 \sim \mathcal{N}_n(\delta + \Lambda \eta_j, \sigma_\varepsilon^2 I_n)$$

$$\eta_j \mid c_j = l \sim \mathcal{N}_r(\mu_l, \Sigma_l), \quad (\mu_l, \Sigma_l) \sim \text{NIW}(m_0, \kappa_0, \nu_0, S_0)$$

$$c_j \mid \rho \sim \text{Categorical}(\rho) \quad \rho \sim \text{Dirichlet}(\mathbf{e}_0, \dots, \mathbf{e}_0)$$

- x_j : item j 가 모든 respondent 와 가지는 거리 관계. (respondent profile)
- x_j 는 $\delta + \Lambda \eta_j$ 를 평균으로 가지는 normal distribution 을 prior 로 가진다.
 - δ : baseline effect. (x_j 자체가 row - centered 이므로 0 에 가까운 값을 가짐.)
 - Λ : respondent profile 의 factor loading
 - η_j : item j 의 respondent profile 의 factor score. (clustering 대상)

PPCA-based latent factor mixture clustering model

PPCA-FMC (item factor mixture clustering)

$$x_j = \log \|a_i - b_j^{(\ell)}\| \quad (\text{row-centered})$$

$$x_j \mid \delta, \Lambda, \eta_j, \sigma_\varepsilon^2 \sim \mathcal{N}_n(\delta + \Lambda \eta_j, \sigma_\varepsilon^2 I_n)$$

$$\eta_j \mid c_j = l \sim \mathcal{N}_r(\mu_l, \Sigma_l), \quad (\mu_l, \Sigma_l) \sim \text{NIW}(m_0, \kappa_0, \nu_0, S_0)$$

$$c_j \mid \rho \sim \text{Categorical}(\rho) \quad \rho \sim \text{Dirichlet}(\mathbf{e}_0, \dots, \mathbf{e}_0)$$

- c_j : mixture distribution 의 indicator 변수
 - ρ : K_+ 길이의 vector. mixture distribution 에서 개별 distribution 할당 확률.
- mixture distribution 은 K_+ 개의 $\mathcal{N}_r(\mu_l, \Sigma_l)$ 분포의 mixture 로 이루어져 있음.
 - $\mathbf{e}_0$ 이 0에 가까운 값을 가지게 되면, ρ 가 균일하게 분포되기보다 특정 위치에 질량이 모이게 되므로 cluster 할당이 특정 cluster 에 모이게끔 할 수 있다.

PPCA-based latent factor mixture clustering model

NIW conjugate prior

NIW mixture prior

$$\Sigma_l \sim \text{IW}(\nu_0, S_0), \quad \mu_l \mid \Sigma_l \sim \mathcal{N}_r\left(m_0, \frac{1}{\kappa_0} \Sigma_l\right) \quad (\text{NIW})$$

- NIW 는 gaussian likelihood 와 conjugate 하므로 (μ_l, Σ_l, ρ) 를 integrate out 하여 c_j 의 collapsed posterior predictive 를 closed-form 으로 얻을 수 있음.
- Posterior predictive 는 multivariate Student- t :

$$P(c_j = l \mid c_{-j}, \eta) \propto (n_{l,-j} + e_0) t_{d_{l,-j}}\left(\eta_j; m_{l,-j}, V_{l,-j}^{\text{pred}}\right)$$

- $n_{l,-j}$: item j 를 제외했을 때 cluster l 에 할당된 item 수
- $m_{l,-j}$: cluster l 의 현재 assigned latent factors 에 기반한 posterior predictive location
- $V_{l,-j}^{\text{pred}}$: cluster l 의 covariance uncertainty 를 반영한 posterior predictive scale matrix
- μ_l, Σ_l 에 조건부로 update 하지 않으므로, 초기 μ_l, Σ_l 가 data 에 부적합하게 할당되어 특정 cluster 가 비어 버리는 문제를 완화

PPCA-based latent factor mixture clustering model

Posterior predictive quantities under NIW prior

NIW posterior update

item j 를 제외했을 때, cluster l 에 할당된 latent factors 를

$$\eta_{\mathcal{I}_{l,-j}} = \{\eta_i : c_i = l, i \neq j\}, \quad n_{l,-j} = |\mathcal{I}_{l,-j}|$$

라고 하자. $n_{l,-j} > 0$ 일 때,

$$\bar{\eta}_{l,-j} = \frac{1}{n_{l,-j}} \sum_{i \in \mathcal{I}_{l,-j}} \eta_i, \quad C_{l,-j} = \sum_{i \in \mathcal{I}_{l,-j}} (\eta_i - \bar{\eta}_{l,-j})(\eta_i - \bar{\eta}_{l,-j})^\top.$$

NIW conjugacy 에 의해 posterior hyperparameter 는 다음과 같이 계산된다.

$$\kappa_{l,-j} = \kappa_0 + n_{l,-j}, \quad \nu_{l,-j} = \nu_0 + n_{l,-j},$$

$$m_{l,-j} = \frac{\kappa_0 m_0 + n_{l,-j} \bar{\eta}_{l,-j}}{\kappa_0 + n_{l,-j}},$$

$$S_{l,-j} = S_0 + C_{l,-j} + \frac{\kappa_0 n_{l,-j}}{\kappa_0 + n_{l,-j}} (\bar{\eta}_{l,-j} - m_0)(\bar{\eta}_{l,-j} - m_0)^\top.$$

PPCA-based latent factor mixture clustering model

Definition of $m_{l,-j}$ and $V_{l,-j}^{\text{pred}}$

- $m_{l,-j}$ 는 고정된 cluster mean 이 아니라, item j 를 제외하고 cluster l 에 현재 할당된 latent factors 로부터 계산되는 posterior predictive location 이다.
- $V_{l,-j}^{\text{pred}}$ 는 고정된 covariance matrix 가 아니라, μ_l 와 Σ_l 의 posterior uncertainty 를 반영한 posterior predictive scale matrix 이다.

$$d_{l,-j} = \nu_{l,-j} - r + 1, \quad V_{l,-j}^{\text{pred}} = \frac{\kappa_{l,-j} + 1}{\kappa_{l,-j} d_{l,-j}} S_{l,-j}.$$

따라서 collapsed allocation probability 는

$$P(c_j = l \mid c_{-j}, \eta) \propto (n_{l,-j} + \mathbf{e}_0) t_{d_{l,-j}} \left(\eta_j; m_{l,-j}, V_{l,-j}^{\text{pred}} \right).$$

PPCA-based latent factor mixture clustering model

Definition of $m_{l,-j}$ and $V_{l,-j}^{\text{pred}}$

Empty cluster

만약 $n_{l,-j} = 0$ 이면, cluster l 로부터 계산할 data summary 가 없으므로 posterior predictive parameter 는 prior predictive parameter 로 환원된다.

$$\kappa_{l,-j} = \kappa_0, \quad \nu_{l,-j} = \nu_0, \quad m_{l,-j} = m_0, \quad S_{l,-j} = S_0.$$

$$d_{l,-j} = d_0 = \nu_0 - r + 1, \quad V_{l,-j}^{\text{pred}} = V_0^{\text{pred}} = \frac{\kappa_0 + 1}{\kappa_0 d_0} S_0.$$

- 직관적으로 $m_{l,-j}$ 는 j cluster 평균의 위치와 관련한 parameter 이고
- $V_{l,-j}$ 는 새로운 factor score vector η_j 가 해당 cluster 에서 얼마나 퍼져 나올 수 있는가를 의미한다.

PPCA-based latent factor mixture clustering model

Jain-Neal split-merge moves

- Single-site collapsed Gibbs sweep 한 번 후 매 iteration 마다 $M_{SM} = 5$ 회의 **Jain-Neal restricted-Gibbs split-merge** proposal 을 시도.
- Target: NIW-collapsed partition target

$$\pi(c | \eta) \propto \prod_{l=1}^{K^*} \frac{\Gamma(n_l + e_0)}{\Gamma(e_0)} m(\eta_{\mathcal{I}_l})$$

where $m(\eta_{\mathcal{I}_l})$ 는 NIW marginal likelihood.

- acceptance rate:


$$\alpha(c \rightarrow c') = \min \left\{ 1, \frac{\pi(c' | \eta) q(c | c')}{\pi(c | \eta) q(c' | c)} \right\}.$$

- 두 item i, j 를 임의 선택 $\rightarrow$ 같은 cluster 면 **split**, 다른 cluster 면 **merge** 제안.
- 단일-사이트 Gibbs 만으로는 한 번에 한 item 만 옮기므로 큰 cluster 를 두 개로 쪼개는 데 어려움이 있는데, split-merge 가 이를 보완.

PPCA-based latent factor mixture clustering model


S_0 의 elicitation

Joint LSIRM+PPCA-FMC v10 [n=5, K*=10, $\sigma=0.1$, mean K, $\kappa=1.0$, split=0.00] | Case 1: All (bin+con+ctrl)




(a) $S_0 = 0.05$

Joint LSIRM+PPCA-FMC v10 [n=5, K*=10, $\sigma=0.1$, mean K, $\kappa=2.8$, split=0.00] | Case 1: All (bin+con+ctrl)



(b) $S_0 = 0.01$

Joint LSIRM+PPCA-FMC v10 [n=5, K*=10, $\sigma=0.1$, mean K, $\kappa=3.7$, split=0.00] | Case 1: All (bin+con+ctrl)



(c) $S_0 = 0.005$

- NIW hyperparameter 중 S_0 가 가장 sensitive 함. S_0 는 mixture distribution 의 공분산 크기와 관련한 parameter 로, Loose S_0 는 model 이 cluster 를 실제보다 넓다고 믿게 만들어 split 을 억제.
- 현재는 $S_0 = 0.005 \sim 0.01$ 를 사용하고 있는데, 해당 parameter 에 대한 적절한 선정 기준을 제시해야 할 필요가 있음.

PPCA-based latent factor mixture clustering model

factor 차원, cluster 개수 선정

- factor 차원 선정: 현재는 LSIRM 의 MCMC sampling 이 어느 정도 되고 난 후(20000 iter 로 설정한 상태) 얻은 respondent profile matrix 의 분산을 99% 이상 설명할 수 있는 factor 차원(MIDUS data 대상으로 5 개 factor 사용 중)을 선택하여 사용함.
 - 이는 추후에 factor 의 maximum 차원을 설정하고, sampling 과정에서 사용하지 않는 잔여 차원을 shrink 하는 식으로 발전 가능
- cluster 개수 선정: maximum cluster 개수(10개로 설정한 상태)를 설정하고 사용하지 않는 cluster 를 비우는 쪽으로 sampling.
 - 이를 위하여 ρ 의 prior 인 dirichlet 분포의 $e_0 < 1$ 조건을 사용함. (0에 가까울수록 shrinkage 정도 증가)

PPCA-based latent factor mixture clustering model

result summary 방법

cluster 개수와 item 별 cluster 할당 모두 posterior distribution 이므로 결과 summary 필요

- ① co - cluster 결과를 이용하여 co - clustering dissimilarity 를 계산
 - co - clustering dissimilarity = $1 - \text{PSM}$
 - PSM(Posterior Similarity Matrix): item pair 가 전체 iteration 에서 같은 cluster 로 묶이는 비율
- ② co - clustering dissimilarity 를 이용하여 hierarchical clustering 수행.
- ③ cluster 개수의 posterior distribution 의 median 값의 층위에서 hierarchical clustering 결과 반환

simulation study

simulation setting

- Sample size: $n = 150$, $P_1 = P_2 = P_3 = P_4 = 30$ (총 $P = 40$ items).
- LSIRM dim $d = 2$, factor dim $r = 2$, truncation $K^* = 10$, $K_{\text{true}} = 4$.
- True item meta-cluster: 4 개의 diamond 형태 cluster (서로 다른 Σ 형태 포함 - isotropic, anisotropic, rotated).
- 두 모델을 동일 데이터 위에서 비교:
 - ① **Multilayer v10**: 4-layer 그대로 fitting.
 - ② **Unilayer baseline**: 모든 layer 를 column-mean 기준으로 이진화하여 단일 binary matrix 로 stack 후 동일 v10 sampler 로 fitting.

simulation study

evaluation criteria

- LSIRM-side coverage: 각 parameter 별 95% credible interval 의 truth 포함률 + mean width 를 평가.
 - $\alpha^{(\ell)}, \beta^{(\ell)}$ ($\ell = 1, 2, 3$), GRM thresholds $\beta_{jk}^{(4)}$.
 - σ_0^2 : continuous layer 의 normal distribution 의 분산.
 - Distance coverage $|a_i - b_j| \cdot \gamma$.
- Cluster recovery: label switching 문제가 있으므로 label-invariant 한 기준 사용.
 - **ARI** (adjusted Rand index).
 - Posterior similarity matrix $\rightarrow$ average-linkage hierarchical clustering $\rightarrow K_{\text{true}}$ cluster.
- Split/merge acceptance rate 도 함께 기록.

simulation study

adjusted Rand index

Adjusted Rand Index (ARI)는 두 군집화 결과의 일치도를 측정하는 지표로, cluster label의 이름이 아니라 두 관측치가 같은 군집에 속하는지 여부를 pairwise 하게 비교한다.

두 partition 을 $U = \{U_1, \dots, U_R\}$, $V = \{V_1, \dots, V_C\}$ 라 하고,

$$n_{ij} = |U_i \cap V_j|, \quad a_i = \sum_j n_{ij}, \quad b_j = \sum_i n_{ij}$$

라고 하면, ARI 는 다음과 같이 정의된다.

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \frac{(\sum_i \binom{a_i}{2})(\sum_j \binom{b_j}{2})}{\binom{n}{2}}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \frac{(\sum_i \binom{a_i}{2})(\sum_j \binom{b_j}{2})}{\binom{n}{2}}} = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]}.$$


ARI 는 우연에 의한 일치도를 보정한 지표이며, $\text{ARI} = 1$ 은 완전한 일치, $\text{ARI} = 0$ 은 무작위 수준의 일치를 의미한다.

simulation study


result: iteration = 100

simulation 결과 중 sample 하나의 결과 시각화.


true



multilayered



unilayered



setting 자체가 cluster 끼리의 misspecification 이 일어날 수 있는 배치. ARI 의 점수가 상대적으로 낮은 이유가 그래서인듯. simulation setting 에서 좀 더 쉬운 cluster 상황을 상정하고 결과 변화를 report 해야 할 것 같음.

simulation study

result: iteration = 100

Parameter Coverage:

Layer	Discrim. α		Difficulty β		Distance $\gamma\ a_i - b_j\ $	
	Uni	Multi	Uni	Multi	Uni	Multi
1 (binary)		95.3	84.0	94.6		96.0
2 (continuous)		95.5	8.8	92.6		95.3
3 (count)		95.3	82.3	94.9		95.9
4 (ordinal)		95.7	—	95.0		95.8


Element-wise 95% CI coverage (%)

Cluster recovery (ARI):

	Unilayer	Multilayer
ARI	0.200	0.729



MIDUS Timelines, Samples, and Projects



MIDUS data


- 1990 년대에서부터 현재까지 진행중인 미국 panel dataset.
- panel 순서: wave 1 - wave 2 - refresher 1 - wave 3 - refresher 2
- respondent 의 수를 확보하기 위해 wave 2, refresher 1 을 결합하였는데, 추후 이 부분에 대한 정당화가 필요함.
 - refresher 의 경우 panel 조사 과정에서 탈락하는 respondent 들을 보충하기 위해서 시행하는 조사로 이전 wave 와 별개의 respondent 들을 대상으로 함.
 - wave 1 의 경우 biomarker data 가 미비하여 사용할 수 없었음.
 - wave 3 의 경우 wave 2 와 refresher 1 에서의 응답자들을 추적조사한 결과이므로 합친다고 해서 repondent 증가하지 않음
- 우울증을 겪고 있는 respondent 만을 조사하기 위하여 depression(우울) / inhedonia(무쾌감증) 에 대하여 지난 12개월 중(gate) 2주 이상(duration) 거의 매일(frequency) 해당 증상을 겪고 있는 respondent 만을 대상으로 분석했습니다.

variables

- binary: binary 화 한 CESD 설문지 - 일반적인 우울 증상 정도를 측정하기 위한 설문지 도구. 우울 증상을 세분화하기보다는 일반적인 severity 를 측정하는 데 효과적이다.
- count: MIDUS data 에서 찾은 집행기능/언어유창성/기억력 관련 정답 점수 - 총점을 알 수 있는 data 만을 선택하여 오답으로 역코딩하여 사용하였음.
- continuous: 염증 및 스트레스호르몬 지수. 소변검사, 혈액검사를 통해 얻은 염증 수치, 스트레스 호르몬 농도를 사용.
- ordinal(4점척도): MASQ 설문지 - CESD 에 비해 우울 증상을 불안, 우울, 각성 등의 하위분야로 구분함. 해당 연구에서는 불안/각성 부분에 해당하는 문항만을 사용함.

real data analysis


result - hyperparameter setting: $S_0 = 0.005$ and $\epsilon_0 = 0.1$



cluster 개수 K 의 posterior 분포는 주로 3–5개 사이에 위치함. 본 결과에서는 posterior median 값인 $K = 4$ 를 기준으로 hclust를 사용하여 clustering을 요약함.

real data analysis


result - hyperparameter setting: $S_0 = 0.01$ and $e_0 = 0.1$



cluster 개수 K 의 posterior 분포가 2 4 개 사이의 값을 가짐. median 값인 3개로 clustering.


real data analysis

result - hyperparameter setting: $S_0 = 0.01$ and $e_0 = 0.1$



(a) Posterior similarity matrix

Joint LSIRM+PPCA-FMC v10 ($r=5$, $K^*=10$, $e_0=0.1$, mean $K_+ \approx 2.8$, split=0.03) | Case 1: All (bin+con+cnt+)



(b) Item latent positions

상대적으로 명확한 clustering pattern 을 보임. 기억력, 언어유창성을 포함하는 cluster가 cluster 1 으로 편입됨.

real data analysis

result - case 1

- ① (불안 + 자율신경계 각성): MASZ AA 14개, GDA 신체, 소변 NE, sgst_normal + numseries · backcount
- ② (염증 + 실행기능 + 면역대사): IL-6 + CRP + Fibrinogen, SGST 4/5 (set-shifting), B4Q3B(식욕부진) + B4Q1NN(홍통)
- ③ (일반적 우울 / HiTOP Internalizing): CES-D 우울정서 + 긍정정서(역), GDA(불안) 정서 6개, catflu_intrusion(의미유창성)
- ④ (Cortisol / 우울감 / 기억력): Cortisol, 수면(K) + 정신운동(M) + 무력감(T), Word-list 기억력 문항, B4Q1VV(공포/공황), B4Q1P

염증 지표 세 개(IL-6, CRP, fibrinogen)를 cortisol에서 분리해 별도 군집으로 정의.

염증 군집에는 B4Q3B(식욕저하)이 함께 묶였고, 이는 식욕 변화가 모든 우울 증상 중 염증과 가장 강하게 연관된다는 기존 결과와 연결됨.

Cortisol 군집에는 B4Q3K(수면 불안정), B4Q3M(말수 감소/정신운동 지체), B4Q3T(시작 곤란/무력감)이 함께 묶였고, 단어 회상 기억 오류 항목들까지 포함. 이 부분에서도

수면 · 정신운동 · 무력감은 cortisol 매개 우울 아형의 전형적 증상이고 만성 cortisol 상승이 해마를 손상시켜 일화기억을 떨어뜨린다는 것 또한 기존 문헌과 연결.

- ① (불안-신체적 우울-실행기능): MASQ AA 15개, GDA 신체 4개, CES-D, 신체-vegetative, SGST 실행 5개, IL-6(염증) + cortisol
- ② (정서-인지적 우울): CES-D 우울정서, CES-D 긍정정서(역), CES-D 대인관계, GDA 정서 7개, B4Q1B(과각성), B4Q1VV(공포/공황)
- ③ (바이오마커-기억력): Cortisol, CRP + Fibrinogen, Word-list, 기억오류, Cat fluency 오류, Number series 오류

자율신경 각성 증상(심장 두근거림, 떨림 등)이 한 그룹으로, 일반적인 우울/불안 정서 증상이 또 한 그룹으로 구분된 결과는 기존 연구결과와 동일.

그러나 Cortisol과 세 가지 염증 지표(IL-6, CRP, fibrinogen)이 모두 한 군집으로 정의됨. case 1 에서 탐지한 cortisol 과 염증반응의 메커니즘 차이를 구별하지 못함.

- 방법론 정당화를 위한 simulation study 보충과 hyperparameter 선택을 위한 criterion 정식화가 필요
- real data 사용 시에 panel data 두 개를 concatenate 했는데, 이 부분에 대한 정당화 필요
- 해석적으로는 case 1 이 더 많은 finding 을 가지지만, 군집화 결과 자체는 case 2 가 더 견고함. 해당 결과에 대한 정당화가 필요. (+ clustering model 적합 과정에서의 문제일 수 있으므로 모델 튜닝 시도해 볼 필요가 있음)