

1014 labmeeting

윤현석

October 14, 2025

1 previous

binomial - continuous data 이질성 어떻게 해결할 것인가?
copula - 부적절하다.

2 literature review

전반적으로 latent variable 을 사용하면서 binary, continuous type 의 data 를 joint 하게 modeling 하는 방법론들에 대해서 찾아봤습니다.

기본적으로는 glm 의 framework 에서 벗어나지 않았고, 대부분의 경우 latent vector 와 그것에 corresponding 하는 loading 의 구조를 가지고 있었습니다.

hierarchical 한 구조나 혹은 covariance matrix 를 이용하여 명시적으로 data 간의 연관성을 설명하고자 하는 model들이 주를 이뤘습니다.

1. Latent Variable Models for Mixed Discrete and Continuous Outcomes 혼합형(이산 · 연속) 반응을 공동으로 다루기 위해, Sammel (1997)는 지표들이 지수족(예: 이항, 포아송, 정규 등)에 속한다고 가정하고, 공유 잠재변수로 상이한 자료형 간 상관을 유도하는 모형을 제안한다.
한 개인 $i = 1, \dots, N$ 와 지표 $m = 1, \dots, M$ 에 대해

$$g_m(\mu_{im}) = \eta_{im} = x_{im}^\top \beta_m + \lambda_m^\top b_i, \quad b_i \sim \mathcal{N}(0, \Psi),$$

- $g_m(\cdot)$ 는 자료형별 연결함수(이항: logit/probit, 카운트: log 등)
- x_{im} : 공변량
- β_m : 지표별 회귀계수

- λ_m : 잠재요인 적재량
- b_i : 개인 공통의 잠재효과

이다.

조건부 분포 $Y_{im} | b_i$ 는 지수족 형태로

$$f(y_{im} | b_i) = \exp \left\{ \frac{y_{im} \eta_{im} - d(\eta_{im})}{\phi_m} + c(y_{im}, \phi_m) \right\},$$

이며 b_i 를 적분 소거하면 이질적 지표들 간의 잔차상관이 자연스럽게 발생한다.

추정은 (적응)수치적분 또는 몬테카를로 적분을 결합한 EM(Fisher scoring)으로 최대우도를 구하고, 표준오차는 관측 정보행렬(또는 샌드위치)로 계산한다. 해당 방법론은

- 서로 다른 데이터형의 정보를 공유해 추정 효율을 높이고(latent factor 를 통해)
- 공변량 효과와 잠재구조(요인 · 군집)를 동시에 파악하며
- 지표 추가 · 삭제에 유연하게 확장 가능하다는 장점이 있다

다만,

- 서로 다른 타입의 데이터 간 정보의 공유가 latent factor 만을 통해서 되고,
- 특정한 type 의 data가 다른 type 의 data 추정에 명시적으로 도움이 되는 구조는 아니다.
- 오히려 개인 별 data 에 대한 factor analysis 관점에 더욱 가까워 보인다.

2. Generalized latent trait models IRT 맥락에서 서로 다른 자료형(이항 · 순서형 · 연속형 등) 문항을 하나의 잠재공간으로 연결하는 일반화 잠재특성모형을 제안한다.

응답자 $m = 1, \dots, n$, 문항 $i = 1, \dots, p$ 에 대해, 문항별 지수족 관측모형과 GLM 연결함수를 사용하고, 잠재요인 $z_m \in \mathbb{R}^q$ (보통 $z_m \sim \mathcal{N}(0, I_q)$)을 통해 평균을 결합한다:

$$g(x_{im} | z_m) = \exp \left\{ \frac{x_{im} \theta_i(z_m) - b_i(\theta_i(z_m))}{\phi_i} + d_i(\phi_i, x_{im}) \right\}, \quad v_i(\mu_{im}) = \alpha_{i0} + \alpha_i^\top z_m,$$

여기서 $v_i(\cdot)$ 는 문항 i 의 링크함수(이항: logit/probit, 순서형: 누적링크 등), α_i 는 적재량(loadings), ϕ_i 는 분산(혹은 척도) 모수이다. 조건부 독립성 가정 하에 $x_{im} \perp x_{i'm} | z_m$ 가 성립하고, 주변우도

$$L = \sum_{m=1}^n \log f(x_m) = \sum_{m=1}^n \log \int g(x_m | z) h(z) dz$$

를 극대화하여 $\{\alpha_{i0}, \alpha_i, \phi_i\}$ 를 추정한다(가우스-에르미트 수치적분을 결합한 EM 또는 뉴턴-점수법). 추정 후 개인 점수는 사후분포 $h(z_m | x_m) \propto g(x_m | z_m)h(z_m)$ 의 EAP/MAP로 산출한다. 식별은 잠재 공간의 스케일 고정(예: $\text{Var}(z_m) = I_q$)과 일부 적재량 제약으로 확보하며, q 선택은 정보기준(AIC/BIC) 및 적합도 진단으로 수행한다. 이 모형은

- 공변량 없이(측정모형에 집중) 이질적 자료형 문항들을 공통 잠재특성에 적재시켜 문항 난이도/변별 및 응답자 잠재점수를 일관된 척도에서 추정할 수 있게 한다.
- 이 점에서 Sammel (1997) 과는 차이를 가진다.
- 그러나 다른 부분에 대해서는 거의 차이가 없고, Sammel (1997) 의 경우 latent vector 를 이용하여 개인 별 서로 다른 data type 을 가진 outcome 이 어떤 공통구조를 가지는지 분석했다면, Moustaki and knott (2000) 의 경우 개인별로 다른 type 의 설문 문항들이 어떤 공통구조를 가지는지 분석하는 것에 목적을 두는 차이점이 있다.

3. A Correlated Probit Model for Joint Modeling of Clustered Binary and Continuous Responses

Cueorguieva (2001)는 모집단이 클러스터(개체 · 집단)로 묶여 있고 각 관측에서 연속형 y_{i1j} 과 이진형 y_{i2j} 이 함께 측정될 때, 이항 성분을 잠재정규 y_{i2j}^* 의 절단(probit)으로 표현하여 두 성분을 공분산 구조로 연결한 상관 프로빗 혼합모형을 제안한다. 이는 일반적으로 GLLM 으로 불린다.

클러스터 $i = 1, \dots, n$, 클러스터 내 관측 $j = 1, \dots, n_i$ 에 대해

$$\begin{aligned} y_{i1j} &= x_{i1j}^\top \beta_1 + z_{i1j}^\top b_{i1} + \varepsilon_{i1j}, \\ y_{i2j}^* &= x_{i2j}^\top \beta_2 + z_{i2j}^\top b_{i2} + \varepsilon_{i2j}, \quad y_{i2j} = \mathbf{1}\{y_{i2j}^* > 0\}, \end{aligned}$$

여기서 $(b_{i1}^\top, b_{i2}^\top)^\top \sim \mathcal{N}(0, \Sigma)$ 는 클러스터 수준의 (결과 간) 상관, $\varepsilon_{ij} = (\varepsilon_{i1j}, \varepsilon_{i2j})^\top \sim \mathcal{N}(0, \Sigma_e)$ 는 관측 수준의 (결과 간) 상관을 포착한다. 식별을 위해 프로빗 오차의 분산을 $\text{Var}(\varepsilon_{i2j}) = 1$ 로 고정한다. 추정은 주변우도(임의효과 적분)의 최대우도로 수행하며, 수치적분(예: 가우스-에르미트)과 적합도/상관 추정을 통해

- (i) 이질적 자료형 간 연관성의 분해(클러스터/관측 수준)
- (ii) 공변량 효과의 동시 추정
- (iii) 불균형 · 결측 처리의 유연성을 제공한다.

해당 모형은 Sammel (1997) 이나 Moustaki and knott (2000) 과는 다르게 두 결과 사이에 모수의 ‘직접 공유’ 없이 공분산 구조를 통해 정보 결합을 구현한다는 점이 특징이다.

4. Bayesian latent variable models for mixed discrete outcomes 혼합형 이산 반응(이진, 카운트, 이산 생존시간 등)을 하나의 공통 구조로 결합하기 위해, David and Herring (2005)는 “기저 포아송 (latent Poisson) + additive gamma frailty” 모델을 제안한다.

개체 $i = 1, \dots, n$, 결과 유형 $\ell \in \{\text{latency, multiplicity, malignancy}\}$, (필요 시) 이산 시간 t 에 대해 잠재 카운트 $z_{ilt} \in \{0, 1, 2, \dots\}$ 를 두고 관측치 y_{ilt} 를 다음과 같이 정의한다:

Latency: $y_{i,\text{lat},t} = 1\{z_{i,\text{lat},t} > 0\}$, Multiplicity: $y_{i,\text{mult},t} = z_{i,\text{mult},t}$, Malignancy: $y_{i,\text{mal}} = 1\{z_{i,\text{mal}} > 0\}$.

이때 결과별 회귀계수 β_ℓ 와 공변량 x_{ilt} 를 포함하는 평균 η_{ilt} 에 대해

$$z_{ilt} \mid \xi_i, x_{ilt} \sim \text{Poisson}(\eta_{ilt}), \quad \eta_{ilt} = (\xi_i^\top \lambda_\ell) \exp(x_{ilt}^\top \beta_\ell),$$

$\xi_i = (\xi_{i1}, \dots, \xi_{ir})^\top$ 는 서로 독립인 gamma frailty로 $\xi_{ik} \sim \text{Gamma}(\phi_k^{-1}, \phi_k^{-1})$ (평균 1, 분산 $\phi_k > 0$), $\lambda_\ell = (\lambda_{\ell 1}, \dots, \lambda_{\ell r})^\top \geq 0$ 는 결과별 적재량(loadings)이다.

이 구성은

- (i) 공통 요인 ξ_i 를 통해 이질적 이산 반응 간 상관을 유도하고,
- (ii) 포아송 평균-분산 동일 제약을 깨는 추가 분산(과산포)을 자동으로 도입한다.

감마 요인을 적분 소거하면 잠재 포아송의 평균과 분산은

$$E(z_{ij} \mid x_{ij}) = \exp(\nu_j + x_{ij}^\top \beta), \quad \text{Var}(z_{ij} \mid x_{ij}) = E(z_{ij} \mid x_{ij}) + \left(\sum_{k=1}^r \phi_k \lambda_{jk}^2 \right) \exp(2x_{ij}^\top \beta),$$

와 같이 추가 항을 갖는다($\nu_j = \log \sum_k \lambda_{jk}$). 따라서 결과 간 상관과 과산포가 동시에 설명된다.

관측지표의 함축적 분포는 포아송 기반에서 유도되며, 예컨대 $\Pr(y_{i,\text{lat},t} = 1 \mid \xi_i, x) = 1 - \exp(-\eta_{i,\text{lat},t})$, $E(y_{i,\text{mult},t} \mid \xi_i, x) = \eta_{i,\text{mult},t}$ 등으로 정리된다.

본 모형은

- (1) 이진/카운트/이산시간 등 다양한 이산 반응을 하나의 잠재 포아송-감마 요인 구조로 연계하고,
- (2) 결과별 공변량 효과와 결과 간 상관 · 과산포를 동시에 포착할 수 있다.

그러나 기본적으로 discrete data 만을 다루므로 continuous, binary 분포에 대해서 modeling 하기 위해서는 추가적인 설계가 필요할 것으로 보인다.

5. Generalized multilevel structural equation modeling Hesketh (2004) 는 GLLMM framework - GLLM 에 SEM(structural equation model) 을 추가하여 data 간 구조를 다루는 모델을 제안했다.

GLMM 의 framework 를 이용하되, latent variable 간의 관계를 SEM 을 이용하여 명시적 구조를 부여하는 방법론이다. (아직 읽는 중)

2.1 model description

1. Measurement model (generalized factor/IRT)

For individual $i = 1, \dots, n$ and item/indicator $j = 1, \dots, J$,

$$g_j(\mathbb{E}[y_{ij} | \boldsymbol{\eta}_i]) = \nu_j + \boldsymbol{\lambda}_j^\top \boldsymbol{\eta}_i + \mathbf{x}_{ij}^\top \boldsymbol{\beta}_j,$$

where $g_j(\cdot)$ is a link matched to the outcome type (e.g., identity for Gaussian, logit/probit for binary/ordinal, log for counts). $\boldsymbol{\eta}_i$ is the vector of latent variables (factors/random effects), $\boldsymbol{\lambda}_j$ are loadings, ν_j item intercept (or thresholds for ordinal), and $\mathbf{x}_{ij}$ are observed covariates with coefficients $\boldsymbol{\beta}_j$. Conditional on $\boldsymbol{\eta}_i$, y_{ij} follows an exponential-family distribution appropriate for item j .

2. Structural model (SEM on latent variables)

$$\boldsymbol{\eta}_i = \mathbf{B} \boldsymbol{\eta}_i + \boldsymbol{\Gamma} \mathbf{w}_i + \boldsymbol{\zeta}_i, \quad \boldsymbol{\zeta}_i \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}),$$

with acyclic (recursive) $\mathbf{B}$ so that $(\mathbf{I} - \mathbf{B})$ is invertible. Reduced form:

$$\boldsymbol{\eta}_i = (\mathbf{I} - \mathbf{B})^{-1} \boldsymbol{\Gamma} \mathbf{w}_i + (\mathbf{I} - \mathbf{B})^{-1} \boldsymbol{\zeta}_i, \quad \text{Cov}(\boldsymbol{\eta}_i) = (\mathbf{I} - \mathbf{B})^{-1} \boldsymbol{\Psi} (\mathbf{I} - \mathbf{B})^{-\top}.$$

3. Multilevel extension (random effects as latent variables)

For levels $\ell = 1, \dots, L$, introduce level-specific latent variables $\boldsymbol{\eta}_{i\ell}$:

$$g_j(\mathbb{E}[y_{ij} | \{\boldsymbol{\eta}_{i\ell}\}_{\ell}]) = \nu_j + \sum_{\ell=1}^L \boldsymbol{\lambda}_{j\ell}^\top \boldsymbol{\eta}_{i\ell} + \mathbf{x}_{ij}^\top \boldsymbol{\beta}_j,$$

$$\boldsymbol{\eta}_{i\ell} = \mathbf{B}_\ell \boldsymbol{\eta}_{i\ell} + \boldsymbol{\Gamma}_\ell \mathbf{w}_{i\ell} + \boldsymbol{\zeta}_{i\ell}, \quad \boldsymbol{\zeta}_{i\ell} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}_\ell).$$

Random intercepts/slopes are special cases of $\boldsymbol{\eta}_{i\ell}$.

6. Correlated bivariate continuous and binary outcomes: issues and applications

7. A latent variable model with mixed binary and continuous response variables

3 ideation

현재까지의 idea 는

- 두 개의 data type 을 모두 설명하는 latent variable 을 사용한다. - data 사이의 상관은 latent variable 이 해당 데이터에 대해서 가지는 영향도 - 적재량의 상관을 통해서 설명한다.
 - LSJM 에서는 이미 penalty term 의 형태로 latent variable 이 사용되고 있어서 어떻게 적용할 수 있을지?
- 두 개의 data type 을 설명하는 model parameter 간의 공분산구조를 사용한다.
 - LSJM 에서는 각 layer 의 α_ℓ, β_ℓ 간의 공분산구조를 명시할 수 있을 것 같다.

$$g(\Pr(Y_{ij}^\ell = y_{ij}^\ell)) = \alpha_\ell + \beta_\ell d(z_i, z_j)$$

form 에서.

- latent variable 간 관계를 명시적으로 설정하여 구조를 설명한다. (아직 reference 읽어보는중)
 - 예를 들어, edge 가 존재하는 경우에만 communicability 가 관찰된다! 와 같은 가정사항을 추가한다던가...
- likelihood 자체의 scale 을 조정한다? (아직 reference 읽어보는중)
 - k

References

- Cueorguieva, A. (2001). A correlated probit model for joint modeling of clustered binary and continuous responses. *journal of the American Statistical Association*.
- David and Herring (2005). Bayesian latent variable models for mixed discrete outcomes. *Biostatistics*.
- Hesketh, R. (2004). Generalized multilevel structural equation modeling. *Psychometrika*.
- Moustaki and Knott (2000). Generalized latent trait models. *Psychometrika*.
- Sammel, M. Ryan, M. L. M. (1997). Latent variable models for mixed discrete and continuous outcomes. *Journal of the Royal Statistical Society: Series B*.