

1209 labmeeting

윤현석

December 8, 2025

1 introduction

해당 연구는 한 번에 여러 가지 data type 을 가지고 있는 설문지 데이터를 하나의 LSIRM model 로 분석할 수 있게 하는 모델을 개발하는 것을 목적으로 합니다.

이 모델은 설문지 데이터를 하나의 data type 으로 통일하는 과정에서 발생할 수 있는 measurement error 의 발생을 방지하고, 여러 가지 data type 을 한 번에 고려했을 때 각 respondent 가 어떤 성향을 가지고 있는지 더 종합적으로 고려할 수 있게 합니다.

모델의 아이디어는 다음과 같습니다.

- 하나의 설문지 데이터 안에서 서로 다른 data type 이 혼재된 상황에서 설문지 데이터를 동일한 data type 별로 묶어 bipartite network 를 새롭게 정의합니다.
- data type 별로 정의된 bipartite network 는 respondent node 를 공유하는 multilayered network 로 간주할 수 있습니다.
- 따라서 서로 다른 data type 을 가지는 multilayered bipartite network 를 LSIRM 으로 적합하면 모든 설문지 item 과 respondent 를 joint 하게 적합하는 LSIRM 이 됩니다.
- 이 과정에서 Sosa (2022) 가 제안한 multilayered network 를 위한 LSM 의 구조를 사용하여 multilayered bipartite network 를 LSIRM 으로 적합할 수 있습니다.

2 model:Global-local three layer LSIRM model

2.1 Model overview

$i = 1, \dots, n$ 을 respondent 에 대한 index 라고 하고, 각각의 layer index 를 $\ell \in \{1, 2, 3\}$ 라고 하고, 각 layer 별 item 의 index 를 $j = 1, \dots, P_\ell$ 라고 하자.

현재 binary, continuous, count 3개의 data type 을 가지고 있으므로 각 3개의 data type 을 아래의 모델이 joint 하게 학습한다:

- Layer 1 ($\ell = 1$): binary items $Y_{ij}^{(1)} \in \{0, 1\}$,
- Layer 2 ($\ell = 2$): continuous items $Y_{ij}^{(2)} \in \mathbb{R}$ (실제로는 likert 척도 가지는 변수 사용),
- Layer 3 ($\ell = 3$): count items $Y_{ij}^{(3)} \in \{0, 1, 2, \dots\}$.

각각의 layer 는 서로 다른 latent respondent position $a_i^{(\ell)} \in \mathbb{R}^d$, latent item position $b_j^{(\ell)} \in \mathbb{R}^d$, 그리고 global respondent position $z_i \in \mathbb{R}^d$ 을 가지고 있다.

각 latent position 별 distance term 은 아래와 같이 정의한다.

$$D_{ij}^{(\ell)} = \left\| a_i^{(\ell)} - b_j^{(\ell)} \right\|_2.$$

Layer 별 linear predictor 는 아래와 같이 정의된다.

$$\begin{aligned}\eta_{ij}^{(1)} &= \alpha_i^{(1)} + \beta_j^{(1)} - \gamma^{(1)} D_{ij}^{(1)}, \\ \mu_{ij}^{(2)} &= \alpha_i^{(2)} + \beta_j^{(2)} - \gamma^{(2)} D_{ij}^{(2)}, \\ \eta_{ij}^{(3)} &= \alpha_i^{(3)} + \beta_j^{(3)} - \gamma^{(3)} D_{ij}^{(3)}, \quad \mu_{ij}^{(3)} = \exp(\eta_{ij}^{(3)}).\end{aligned}$$

α_i^ℓ 는 ℓ 번째 layer 의 i 번째 respondent 의 ability,

β_j^ℓ 는 ℓ 번째 layer 의 j 번째 item 의 difficulty,

γ^ℓ 는 ℓ 번째 layer 에서 latent position 들이 가지는 영향력의 정도를 의미한다.

각 data 별 분포는 아래와 같이 정의된다.

$$\begin{aligned}Y_{ij}^{(1)} &| \alpha^{(1)}, \beta^{(1)}, \gamma^{(1)}, a^{(1)}, b^{(1)} \sim \text{Bernoulli}\left(\text{logit}^{-1}(\eta_{ij}^{(1)})\right), \\ Y_{ij}^{(2)} &| \alpha^{(2)}, \beta^{(2)}, \gamma^{(2)}, a^{(2)}, b^{(2)}, \sigma_0^2 \sim \mathcal{N}\left(\mu_{ij}^{(2)}, \sigma_0^2\right), \\ Y_{ij}^{(3)} &| \alpha^{(3)}, \beta^{(3)}, \gamma^{(3)}, a^{(3)}, b^{(3)}, \alpha \sim \text{NB}\left(\mu_{ij}^{(3)}, \alpha\right),\end{aligned}$$

여기서 마지막 negative binommmial 은 NB2 parameterization 을 사용하여 linear predicto 가 negative binomial distribution 의 mean 이 될 수 있도록 했다.

따라서 mean 은 $\mu_{ij}^{(3)}$ 이고 dispersion parameter 는 $\alpha > 0$ 로 정의되었다.

2.2 Prior distributions

Global and local latent positions.

이 구조를 통해서 각 layer 별 respondent 의 latent position 은 하나의 global position 에서 sampling

되는 position 으로 정의된다.

$$\begin{aligned} z_i &\sim \mathcal{N}_d(0, I_d), \quad i = 1, \dots, n, \\ a_i^{(\ell)} | z_i, \sigma_1^2 &\sim \mathcal{N}_d(z_i, \sigma_1^2 I_d), \quad \ell = 1, 2, 3, \\ b_j^{(\ell)} &\sim \mathcal{N}_d(0, I_d), \quad \ell = 1, 2, 3. \end{aligned}$$

Respondent and item main effects. (ability, difficulty)

$$\begin{aligned} \alpha_i^{(\ell)} | \sigma_{\alpha,\ell}^2 &\sim \mathcal{N}(0, \sigma_{\alpha,\ell}^2), \\ \beta_j^{(\ell)} | \tau_{\beta,\ell}^2 &\sim \mathcal{N}(0, \tau_{\beta,\ell}^2), \end{aligned}$$

with inverse-gamma hyperpriors (using the code's parameterization)

$$\begin{aligned} \sigma_{\alpha,\ell}^2 &\sim \text{IG}(a_{\sigma}^{(\ell)}, b_{\sigma}^{(\ell)}), \quad \ell = 1, 2, 3, \\ \tau_{\beta,\ell}^2 &\sim \text{IG}(a_{\tau}^{(\ell)}, b_{\tau}^{(\ell)}), \quad \ell = 1, 2, 3. \end{aligned}$$

Global-local variance.

$$\sigma_1^2 \sim \text{IG}(a_{\sigma,\text{global}}, b_{\sigma,\text{global}}).$$

Continuous-layer variance.

$$\sigma_0^2 \sim \text{IG}(a_{\sigma_0}, b_{\sigma_0}).$$

Distance effects and dispersion (log-scale priors).

$$\begin{aligned} \log \gamma^{(\ell)} &\sim \mathcal{N}(\mu_{\log \gamma, \ell}, \sigma_{\log \gamma, \ell}^2), \quad \ell = 1, 2, 3, \\ \log \alpha &\sim \mathcal{N}(\mu_{\log \alpha}, \sigma_{\log \alpha}^2), \end{aligned}$$

with $\gamma^{(\ell)} = \exp(\log \gamma^{(\ell)})$ and $\alpha = \exp(\log \alpha)$.

3 real data analysis:KSAH data

KSAH data 는 여러 scale 의 likert 문항 (3,4,5,7,10) 과 count 응답으로 구성된 문항, binary 응답으로 구성된 문항이 혼재되어 있어 multilayer LSIRM 을 적용하기 적합한 data 임.

item overview

5 score likert scale item

swb, dad, mom, tutor_rel, pss, vaccine, gender

- swb_1-6: 주관적 행복에 대한 문항 (클수록 부정적) - 6번 문항 역코딩함
- dad_1-8: 아버지와의 관계에 대한 문항 (클수록 부정적)
- mom_1-8: 어머니와의 관계에 대한 문항 (클수록 부정적)
- tutor_rel_1-4: 사교육 선생님과 관계에 대한 문항 (클수록 부정적)
- pss_1-10: 스트레스 정도에 대한 문항 (클수록 부정적) - 1,2,3,6,9,10 문항 역코딩함
- vaccine: 코로나-19 백신 의무화 찬성 여부 - (클수록 반대)
- gender_1-2: 성역할에 대한 관점 (클수록 보수적) - 1문항 역코딩함

binary item

cohab, bully, victim, overeating, purging

- cohab_1-11: 각 가족 구성원과의 동거 여부
 - 1: 친아버지
 - 2: 친어머니
 - 3: 새아버지
 - 4: 새어머니
 - 5: 친할아버지
 - 6: 친할머니
 - 7: 외할아버지
 - 8: 외할머니
 - 9: 남자형제
 - 10: 여자형제
 - 11: 기타사람
- bully: 학교폭력 가해여부 (1 - 가해)

- victim: 학교폭력 피해여부 (1 - 피해)
- overeating: 지난 3개월간 과식 여부 (1 - 과식함)
- purging: 지난 3개월간 완하제 복용 여부(배변을 쉽게 하는 약이나 식품) (1 - 섭취함)

count item

tutor_h, wday_slp_h, wday_std_h, wend_slp_h, wend_std_h

- tutor_h: 일주일 기준 사교육 시간
- wday_slp_h: 일주일 기준 수면시간
- wday_std_h: 일주일 기준 학교 수업 외 공부시간
- wend_slp_h: 일주일 기준 주말 수면시간
- wend_std_h: 일주일 기준 주말 공부시간

3.1 result

3.1.1 5 score likert data






Figure 1: 5-score likert scale item

Isirm 결과와 item clustering 경향은 맞아 보입니다.

3.1.2 binary data



(a) global-local structure




(b) standard lsirm


Figure 2: binary item

lsirm 결과와 item clustering 경향은 거의 유사합니다. (12,13 - 학교폭력 경험) / (14,15 - 과식, 완하제 복용 여부) clustering 되어 있는 것 공통적임.

그러나 lsirm 에서 respondent 가 강하게 clustering 되어 있는 경향성과는 다르게 global local structure 에서는 cluster 경향성이 상대적으로 약하게 나타나고, latent position 자체도 다릅니다. 이는 global 및 다른 local 구조에 영향을 받은 것으로 보입니다.



(a) count item



(b) 사교육 시간 histogram

Figure 3: binary item

3,5 문항은 일주일 공부시간, 주말 공부시간, 2,4 문항은 일주일 수면시간, 주말 수면시간으로 응답 패턴이 유사한 것이 자연스럽습니다. 1은 일주일 기준 사교육 공부시간입니다. 전체 분포는 위와 같은데, 여기서 공부시간 20시간 이상이라고 응답한 respondent 를 초록색으로 칠해 놓았습니다.

경향성 복원은 어느 정도 되는 것 같아서 이제 이 결과를 어떤 식으로 해석할 수 있을지 고민중입니다.

또한 respondent 의 position 이 layer 별로 지나치게 이질적인 부분이 있는 것 같습니다. 이 경우, 각 data 별 응답 경향의 차이가 있는 것으로 이해할 수 있을 것 같습니다. 그러나 해당 모델의 목적은 모든 종류의 item 에 대한 respondent 의 position 을 joint 하게 추정하는 것이므로, layer 별 position 의 지나친 이질성을 어떻게 컨트롤 할 수 있을지 고민해 보아야 할 것 같습니다. (혹은 정당화할 수 있을지)

References

Sosa, Juan. Betancourt, B. (2022). A latent space model for multilayer network data. *Computational Statistics & Data Analysis*.