

review: Latent Variable Models for Mixed Discrete and Continuous Outcomes

윤현석

October 9, 2025

1 intro

어떠한 조치에 대한 반응은 multiple outcome 으로 나올 수 있다. 예를 들어 birth defects(아마 선천적 결함으로 번역되는 듯)에 대한 결과는 major malformation 과 같이 binary 한 변수로 나올 수도 있으나, subsequent functioning and development (예를 들어 성장 불균형) 처럼 continuous 한 변수로 관찰될 수도 있다. 따라서 여러 종류의 outcome 을 가지는 원인에 대한 modeling 을 joint 하게 구현해야 할 필요가 있다.

2 model

2.1 problem setting & model description

- M : number of outcome type
- N : number of individuals
- data format: $y_i = (y_{i1}, \dots, y_{iM})^T$ - individual i 는 1 ~ M 개 종류의 outcome 을 가진다.
- b_i : unobserved latent variable that directly influence to y_i (therefore y_i is physical manifestation of variable b_i .)
- 해당 논문에서는 y_i 가 모두 exponential family 를 따른다고 가정하므로, y_i distribution 은 아래와 같이 서술할 수 있다.

$$f_m(y_{im}|b_i) = \exp [\{y_{im}\eta_m - d(\eta_m)\}/\phi_m + c_m(y_{im}, \phi_m)]$$

- $\mu_m = E(y_{im}) = d'(\eta_m)$
- $V_m = \text{var}(y_{im}) = d''(\eta_m)$

- y_{im} 의 분포를 결정하는 η_m 은 아래와 같이 모델링 할 수 있는데, 이는 latent variable 과 다른 fixed covariate 의 linear combination 으로 결정된다.

$$\eta_m = \beta_{0m} + b_i\beta_{1m} + u_{i1}\beta_{2m} + \cdots + u_{ip}\beta_{(1+p)m} = x_i^T \beta_m$$

- modeling 의 중점은 η_m 에서 b_i 에 해당하는 β_{1m} 이 outcome type 별로 어떻게 추정되느냐에 따른다. 이는 factor analysis 의 관점에서 바라보면 이해가 수월하다. 이해를 조금 더 빠르게 하기 위해 b_{i1}, b_{i2} 두 개의 random effect 가 존재한다고 생각해 보자.

- b_{i1}, b_{i2} 는 개인별로 할당된 factor 라고 할 수 있다.
- b_{i1}, b_{i2} 에 corresponding 하는 factor loading 을 β_{1m1}, β_{1m2} 라고 하면, 아래와 같이 η_m 을 linear combination 으로 쓸 수 있다.

$$\eta_m = \beta_{0m} + b_{i1}\beta_{1m1} + b_{i2}\beta_{1m2} + u_{i1}\beta_{2m} + \cdots + u_{ip}\beta_{(1+p)m} = x_i^T \beta_m$$

- 그러면 우리는 개인별로 특정 outcome 이 factor 들에 대해서 할당되는 factor loading 을 분석할 수 있고, 이를 이용해서 어떤 outcome 들이 잠재변수 b_{i1} 의 영향을 많이 받는지 묶을 수 있다. → factor analysis 가 가능함.
- 이런 방식을 통해서 phenotype 분석 등에 해당 모델을 사용할 수 있는 이유는, 개인 별 여러 가지 형태의 outcome이 있는데, 이것들이 특정한 조치를 한 - 예를 들어서 특정 유전자 type 을 변경한 - example 들일 때 해당 유전자 type 변경이 여러 가지 outcome 들에 대해서 joint 하게 영향을 미치는지를 regression model 로 확인하고자 할 때 유용하기 때문이다.

* 특히, glm format 이므로 다른 변수의 개입을 통제할 수도 있으므로 인과관계 확인에 용이할 것이다.

- y_i 의 marginal distribution 은 아래와 같이 서술될 수 있다.

$$f(y_i) = \int f(y_i|b_i)f(b_i;\theta)db_i$$

- θ : b_i 의 분포를 결정하는 미지의 모수 - 추정의 대상

2.2 estimation

EM algorithm 채용하는데, 내가 쓸 것 아니기 때문에 skip

3 critic

- 결국 추정 방법만 생각했을 때는 b_i 이 random variable - random effect 가 되는데, 해당 random effect 를 여러 데이터 type 들이 공유하도록 mapping 함으로써 정보를 공유할 수 있게 하는 모델이다.
- model 의 중점 목표는 heterogeneity 를 해소하는 것이 아니라, 통합적인 framework 상에서 서로 다른 type 의 data 를 어떻게 분석할 것인가임. 그래서 heterogeneity 를 명시적으로 '해소하는' model 은 아니다.
- 아마 해당 모델이 발전하면 GLLVM(generalized linear latent variable model) 이 될 것 같은데... LSM 에 어떻게 적용할 수 있을지는 좀 더 생각해 봐야 할 것 같다.

References