

why discrete data has less information than continuous data in GLM setting?

윤현석

October 8, 2025

1 intro

왜 glm setting 에서 discrete data 와 continuous data 를 그냥 joint 해서 쓰면 안되는가?
여기에는 여러 이유가 있을 수 있으나, 가장 우선적으로는 glm setting 에서 각각의 data 가 model 에 제공하는 정보량의 차이가 존재한다는 근본적인 문제가 있다.
binary data 에 비해 continuous data 가 glm 모델에 정보를 더 강하게 부여하고, 따라서 joint model fitting 과정에서 정보 불균형이 발생하고, 이는 추정의 bias 를 초래한다.

2 concepts

여기서는 GLM 을 IRLS 방법을 이용해서 최적화 하는 과정에서 왜 binary value 와 continuous value 의 information 차이가 존재하는지를 설명한다.

2.1 fisher information

- wiki definition: the Fisher information is a way of measuring the amount of information that an observable random variable X carries about an unknown parameter θ of a distribution that models X .
 - fisher information 은 data X 가 모델의 분포를 결정하는 미지의 parameter θ 에 대해 얼마만큼의 정보를 제공하는지에 대한 측정 방법이다.
- 아래와 같이 정의된다.

$$\mathcal{I}(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \mid \theta \right] = \int_{\mathbb{R}} \left(\frac{\partial}{\partial \theta} \log f(x; \theta) \right)^2 f(x; \theta) dx$$

- θ : parameter unknown
- X : data known
- 해당 식은 score function 의 제곱의 expectation 으로 정의된다고도 볼 수 있다. score function 의 정의는 아래와 같다.
 - $\frac{\partial}{\partial \theta} \log f(X; \theta)$

2.2 exponential family in GLM

- exponential family 의 canonical form 은 다음과 같다.

$$h(X) \exp \{ \eta(\theta) \cdot T(X) - A(\theta) \}$$

- 여기서 $T(X)$ 는 sufficient statistic 이고,
- θ 는 model 을 결정짓는 parameter 이다.
- 또한 $h(X)$ 는 non - negative function 이어야 한다.
- 또한 data X 가 따르는 분포의 sufficient statistic $T(X)$ expectation 과 variance 는 아래와 같이 정의된다.
 - * $\mathbb{E}[T(Y)] = A'(\eta)$
 - * $Var[T(Y)] = A''(\eta)$

item 그런데 해당 식에서 '산포' 모수를 표기해서 쓰면 평균구조와 산포를 따로 추정, 검정하기 쉬워지므로 새로운 form 으로 쓸 수 있다고 한다.

$$f(X|\theta, \phi) = \exp \left\{ \frac{1}{a(\phi)} \{ T(X) \cdot \theta - b(\theta) \} + c(X, \phi) \right\}$$

- 여기서 $a(\phi)$ 가 산포도를 의미한다.
- 기존 form 과는 아래와 같이 mapping 된다.
 - * $\eta(\theta) = \frac{\theta}{a(\phi)}$
 - * $A(\theta) = \frac{b(\theta)}{a(\phi)}$
 - * $h(X) = \exp c(X, \phi)$
- 또한 data X 가 따르는 분포의 sufficient statistic $T(X)$ 의 expectation 과 variance 는 아래와 같다.
 - * $\mathbb{E}[T(Y)] = \frac{\partial A}{\partial \eta}(\eta, \phi) = b'(\theta)$
 - * $Var[T(Y)] = \frac{\partial^2 A}{\partial \eta^2}(\eta, \phi) = a(\phi) b''(\theta)$

2.3 GLM

generalized linear model 의 경우 exponential family 에 속하는 distribution 을 data 가 따른다고 가정했을 때 적절한 link function 을 이용하여 해당 data 와 distribution 의 관계를 선형적으로 연결해 주는 model 을 의미한다.

기본적인 linear model 은 다음과 같이 쓸 수 있다.

$$y = \beta^T x + \epsilon \quad \epsilon \sim D(\cdot)$$

여기서 $D(\cdot)$ 을 임의의 분포라고 했을 때, epsilon 으로 인해서 Y 에 분포가정이 들어가고, data X 와 covariate β 를 알고 있을 때의 Y 의 분포를 얻을 수 있다. 그런데, 이 때 Y 가 가질 수 있는 값과 해당 선형식이 가질 수 있는 값이 바로 matching 되지 않을 수 있다. 예를 들어 Y 는 non - negative 값만 가질 수 있는데 선형식은 (항상) $-\infty, \infty$ 값을 가질 수 있는 경우. 이 경우 Y 분포에 exp 를 추가함으로써 Y 의 분포와 선형식의 output 을 맞춰줄 수 있다. 여기서 사용한 log 를 link function 이라 하고 일반적으로 $g(\cdot)$ 이라고 쓴다. 그렇다면 우리는 GLM 식을 아래와 같이 정리할 수 있다.

$$g(\mathbb{E}[Y]) = \beta^T X$$

Y 의 범위에 따라서 알맞은 link function 과 분포가정을 채용하여 GLM 을 만들 수 있다.

3 explanation

3.1 fisher information - hessian

특정 data 가 특정 model setting 하에서 가지는 정보의 linear operation 을 fisher information 이라고 할 수 있다. (parameter 가 vector 의 형태면 hessian matrix 의 형태로 나타나기 때문 - loglikelihood 의 second derivative 이므로)

따라서 우리는 특정 data 형태에 따른 fisher information 의 차이를 통해서 정보량의 차이를 볼 수 있다. 먼저 일반형을 구해 보면 아래와 같이 구해진다. (자세한 유도는 생략하였음.)

- 먼저 log - likelihood 를 다음과 같이 정의하였음: $\ell_i(\beta) = \frac{T(y_i)\theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi)$
- 이후 해당 model 에 대해서 second derivative 를 구하면 아래와 같은 결과를 얻을 수 있고, 해당 결과가 국소적 fisher information 이 된다. (특정 data 의 곡률)

$$\frac{\partial^2 \ell_i}{\partial \beta \partial \beta^T} = \frac{1}{a(\phi)} \left[\frac{-(m'_i)^2 + r_i m''_i}{V(\mu_i)} - \frac{r_i (m'_i)^2 V'(\mu_i)}{V(\mu_i)^2} \right] x_i x_i^T$$

such that,

- $m'_i = \frac{d\mu_i}{d\eta_i} = \frac{1}{g'(\mu_i)}$
- $\eta_i = x'_i\beta, \quad \mu_i = g^{-1}(\eta_i)$
- $r_i = T(Y_i) - \mu$
- x_i - i 번째 설명변수 vector (binary, continuous 에서 동일하게 사용할 수 있음)

and in matrix form,

$$\nabla_{\beta}^2 \ell(\beta) = \sum_i \frac{\partial^2 \ell_i}{\partial \beta \partial \beta^T}$$

and using expectaion, since $\mathbb{E}[r_i] = 0$,

$$-\mathbb{E} \left[\frac{\partial^2 \ell_i}{\partial \beta \partial \beta^T} \right] = \frac{1}{a(\phi)} \frac{(m'_i)^2}{V(\mu_i)} x_i x_i^T$$

Therefore,

$$\mathcal{I}(\beta) = -\mathbb{E} [\nabla_{\beta}^2 \ell(\beta)] = \sum_i w_i x_i x_i^T = X^T W X$$

, $W = \text{diag}(w_i, \dots, w_n)$

such that:

$$w_i = \frac{1}{a(\phi)V(\mu_i)} \left(\frac{d\mu_i}{d\eta_i} \right)^2 = \frac{(m'_i)^2}{a(\phi)V(\mu_i)}$$

3.2 comparing between binary, continuous data

이제, 해당 matrix form 을 binary, continuous data 에 대한 glm 을 통해 얻은 결과라고 생각했을 때 해당 hessian matrix 의 크기 비교를 할 수 있다.

fisher information 의 크기 비교는 임의의 data 가 존재할 때, 해당 data 에 대한 해당 matrix 의 quadratic form (fisher information 의 정의) 의 크기가 어떻게 차이가 나는가를 통해 비교할 수 있다. - 다시 말하면, 해당 linear operator 가 특정 data point 에 대해 만들어 내는 linear operation 의 크기를 비교하는 것이다. 먼저 두 개의 lemma 를 참고하자.

lemma A if $M \succeq 0$ then, $X^T M X \succeq 0$ for $\forall X$

lemma B if $0 \prec A \preceq B$ then $B^{-1} \preceq A^{-1}$

먼저, 일반적으로 두 개의 matrix W, W' 있다고 할 때 by lemma A,

if $W' - W \succeq 0$ then, $X^T (W' - W) X \succeq 0 \rightarrow X^T W' X \succeq X^T W X$ 이라고 할 수 있다. 그리고

이는 fisher information form 이므로, $\mathcal{I}(\beta') \geq \mathcal{I}(\beta)$ 라고 할 수 있다. ($\mathcal{I}(\beta') = X^T W' X$)

이제, logistic link function 을 사용한 binary data 와 identity link function 을 사용한 continuous data 를 비교해 보자.

세부 증명은 생략하고, 각 data 들의 W matrix 는 아래와 같은 form 을 가진다.

- logistic $W = \text{diag}\{p_i(1 - p_i)\}$

- gaussian $W' = \frac{1}{\sigma^2} \mathbb{I}$

따라서,

$$X^T W X \preceq X^T \left(\frac{1}{4}\mathbb{I}\right) X$$

이므로, $X^T W' X = X^T \frac{1}{\sigma^2} \mathbb{I} X$ 인 continuous data 의 fisher information 이 언제든지 binary data 의 fisher information matrix 보다 모든 data point 에서 linear transportation 을 크게 할 수 있다는 것이다. → 정보량이 크다는 것.

References